

分类号: X824

密 级: 公开

U D C:

单位代码: 11646

宁波大学

硕士学位论文

论文题目: 2 种不同内陆水体浮游藻类发生动态及预测模型构建

学 号: G08B09080110
姓 名: 张克鑫
专 业 名 称: 水产养殖
学 院: 生命科学与生物工程学院
指 导 教 师: 陆开宏

论文提交日期: 2011 年 1 月 5 日

A Thesis Submitted to Ningbo University for the Master's Degree

**The dynamic changes of phytoplankton and the construction of
predicting model in two different kinds of inland water**

Candidate: Zhang KeXin

Supervisors: (Associate) Professor Lu KaiHong

Faculty of life science and biotechnology
Ningbo University
Ningbo 315211, Zhejiang P.R.CHINA

Date: Jan.5,2011

独 创 性 声 明

本人郑重声明：所呈交的论文是我个人在导师指导下进行的研究工作及取得研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得宁波大学或其他教育机构的学位或证书所使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中做了明确的说明并表示了谢意。

若有不实之处，本人愿意承担相关法律责任。

签名：_____ 日期：_____

关于论文使用授权的声明

本人完全了解宁波大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

（保密的论文在解密后应遵循此规定）

签名：_____ 导师签名：_____ 日期：_____

2 种不同内陆水体浮游藻类发生动态及预测模型构建

摘 要

水体富营养化及其引发的藻类水华爆发已经成为 20 世纪以来世界范围内的重要环境问题之一。藻类水华的出现,尤其是饮用水水体藻类水华的出现,不仅降低了水体各营养级物种多样性,弱化了水体生态系统的功能,而且对人类的生活和生产都造成了严重的威胁。为了更好的实现对藻类水华的应急监测和预报预警,BP 人工神经网络方法已被广泛的运用于水生态预测模型的构建中。

本研究选取了 2 种不同类型的内陆水体作为研究对象,其中一种是两个具有代表性的饮用水水库,分别是奉化市的亭下水库和慈溪市的梅湖水库,这两个水库都是富营养型水库,并且时常有藻类水华的发生;另一种是一个位于宁波大学校内的小型池塘,该池塘富营养化严重,多年发生藻类水华。对两个饮用水水库的理化以及生物指标进行了为期一年的跟踪监测,研究了水体藻类动态变化和各理化因子之间的关系,并基于 BP 人工神经网络构建了水体叶绿素 a 浓度的预测模型;而对校内小型藻华水体进行了为期 30 周的连续跟踪调查研究,研究了藻类发生动态及其与水体各理化因子之间的关系,并基于 BP 人工神经网络构建了水体颤藻水华的预测模型,并对藻华水体浮游植物群落结构进行了研究。主要研究结果归纳如下:

1.2009 年 2 月至 2010 年 1 月间对奉化市亭下水库进行了为期一年的跟踪调查研究,监测项目中包括 pH 值、溶解氧(Dissolved Oxygen, DO)、水温(Water Temperature, WT)、透明度(Secchi Depth, SD)、总氮(Total Nitrogen, TN)、硝氮(Nitrate Nitrogen, $\text{NO}_3\text{-N}$)、氨氮(Ammonium Nitrogen, $\text{NH}_3\text{-N}$)和叶绿素 a 浓度(Concentration of Chlorophyll-a, Chl-a)这 8 个水体的理化因子以及浮游植物和浮游动物等生物因子。利用主成分分析法从 pH、DO、WT、SD、TN、 $\text{NO}_3\text{-N}$ 、 $\text{NH}_3\text{-N}$ 这 7 个环境变量中选出 pH、DO、WT、SD、TN 和 $\text{NO}_3\text{-N}$ 这 6 个环境变量作为构建模型时的网络输入变量,并基于 BP 人工神经网络和 Matlab7.0 软件,以水体叶绿素 a 浓度作为网络输出变量,构建了亭下水库叶绿素 a 浓度的预测模型。模型输出结果显示:叶绿素 a 浓度预测值与实测

值之间的相关系数达到了 0.768, 叶绿素 a 浓度预测曲线和实测曲线之间的拟合程度良好, 说明构建的 BP 神经网络能够较为准确的反映亭下水库叶绿素 a 浓度的变化趋势。模型确定后, 为了进一步探究哪些输入的环境变量是影响亭下水库叶绿素 a 浓度的主要因素, 对构建的模型进行了敏感度分析, 敏感度分析结果显示: 水体的温度是影响亭下水库叶绿素 a 浓度的主要因素, 且 pH 与叶绿素 a 浓度呈显著相关, 水温和 pH 是影响亭下水库藻类生长的主要驱动因子。

2.2009 年 2 月至 2010 年 1 月间对慈溪市梅湖水库进行了为期一年的跟踪调查研究, 监测项目与亭下水库的相同, 并利用主成分分析法选出了 DO、WT、TN、NO₃-N 和 NH₃-N 这 5 个环境变量作为构建模型时的网络输入变量, 并基于 BP 人工神经网络和 Matlab7.0 软件, 以水体叶绿素 a 浓度作为网络输出变量, 构建了梅湖水库叶绿素 a 浓度的预测模型。模型输出结果显示: 叶绿素 a 浓度预测值与实测值之间的相关系数达到了 0.877, 叶绿素 a 浓度预测曲线和实测曲线之间的拟合程度良好, 说明构建的 BP 神经网络能够很好的反映梅湖水库叶绿素 a 浓度的变化趋势。模型确定后, 为了进一步探究哪些输入的环境变量是影响梅湖水库叶绿素 a 浓度的主要因素, 对构建的模型进行了敏感度分析, 敏感度分析结果显示: 水体的温度和硝氮含量是影响梅湖水库叶绿素 a 浓度的主要因素, 也是影响梅湖水库藻类生长的主要驱动因子。

3.2009 年 3 月至 2009 年 10 月间对宁波大学校内小型藻华水体进行了为期 30 周的连续跟踪调查研究, 监测项目中包括 TN、总磷 (Total Phosphorus, TP)、SD、DO、pH 和 WT 这 6 个环境变量以及浮游植物生物量, 特别是水体中颤藻 (*Oscillatoria*) 生物量。用以上 6 个环境变量第 (n-1) 周和第 (n-2) 周的监测数据为网络输入, 以第 n 周颤藻生物量的监测数据为网络输出, 基于 BP 人工神经网络和 Matlab7.0 软件, 构建了小型藻华水体藻类水华的预测模型, 对藻华水体的颤藻生物量进行了短期预测, 并对构建的模型进行了敏感度分析。结果显示: (1) BP 神经网络模型对颤藻生物量预测值与实测值之间拟合程度良好, 相关系数达到了 0.984, 说明 BP 神经网络模型可以用于水体中藻类水华的短期预测。(2) 通过对构建的 BP 神经网络模型进行敏感度分析, 阐明了宁波大学校内池塘藻类水华的主要驱动因素, 并指出控制水体的 PH 值是宁波大学校内池塘藻类水华防治工作的重点。

4. 以宁波大学校内池塘 2009 年 3 月至 10 月间 30 周的监测数据为基础, 根据其跟踪监测的水化和生物指标, 基于 PRIMER5.0 群落结构多元统计分析软件, 利用其中的非度

量多维尺度转换排序（Non-metric Multi-Dimensional Scaling MDS）和聚类分析（CLUSTER）等多元统计分析方法，探求采样池塘浮游植物群落结构的动态变化及其与环境因子的关系。结果表明，采样池塘的优势藻类是蓝藻和绿藻，且其繁盛过程分为绿藻期、绿藻和蓝藻期和蓝藻期三个阶段，并存在着这两个优势藻类群落演替的过程。通过对采样池塘整个浮游植物群落和蓝藻群落与环境因子之间进行 RELATE 相关性检验及 BIO-ENV 匹配性分析结果可知，采样池塘整个浮游植物群落和环境因子的相关系数 $R=0.489$ ，显著水平 $P=0.1\%$ ；采样池塘蓝藻群落和环境因子的相关系数 $R=0.449$ ，显著水平 $P=0.1\%$ ，两个群落与池塘环境因子之间的相关性都是极其显著的。并且 SD 和 pH 这两个环境因子是采样池塘整个浮游植物群落结构的最佳环境因子组合，而 SD、pH 和 WT 是采样池塘蓝藻群落结构的最佳环境因子组合。另外，pH 既是采样池塘整个浮游植物群落的关键控制因素，也是蓝藻群落的关键控制因素，且 pH 与采样池塘整个浮游植物群落之间的相关系数达到了 0.711。

关键词：浮游藻类，叶绿素 a 浓度，BP 神经网络，预测模型，群落结构，多元统计分析

The dynamic changes of pHytoplankton and the construction of predicting model in two different kinds of inland water

Abstract

The rapid development of agriculture causes the water eutrophication, the occurrence of algae blooms in eutrophic water bodies has become one of the most important and difficult worldwide environmental problems since the 20th century. The occurrence of algae blooms, especially in drinking water, not only decline the specific biodiversity at all trophic and there is a deterioration of the ecosystem function, but has caused a serious threat for human life and production. In order to better achieve the emergency monitoring and forecasting warning of algae blooms, BP artificial neural network method has been widely used in the construction of predicting model in water ecology.

This study selected two different types of inland water as the research object, one kind of them is two typical reservoir for drinking water, which are the Tingxia Reservoir in Fenghua city and the Meihu Reservoir in Cixi city. The two Reservoirs both the eutrophic reservoir, and often occur algae blooms, the other is a small-scale pond that lie in Ningbo University, the pond is a severe eutrophic pond and occur algae blooms in many years. We had monitored the indicators of physical and chemical and biological to the two drinking reservoirs for year, and had researched the relationship between the dynamic changes of phytoplankton and the indicators of physical and chemical. Constructed the predicting model of the Concentration of Chlorophyll-a Based on BP Neural Network. Besides, We had monitored the indicators of physical and chemical and biological to the small-scale pond for 30 weeks, also researched the relationship between the dynamic changes of phytoplankton and the indicators of physical and chemical, and constructed the predicting model of Algal Blooms Based on BP Neural Network, besides, we studied the community structure of phytoplankton in the pond of Algal blooms. The main results are summarized as follows:

1. We monitored the Tingxia Reservoir in Fenghua city between February 2009 and January 2010 for year. The monitor project including 8 physical and chemical factors that are pH

value, dissolved oxygen(DO), water temperature(WT), transparency (SD), total nitrogen (TN), nitrate nitrogen ($\text{NO}_3\text{-N}$), ammonium nitrogen ($\text{NH}_3\text{-N}$) and concentration of Chlorophyll-a (Chl-a) and the biological factors of phytoplankton and zooplankton. Using principal component analysis method to select 6 environmental factors such as PH value, dissolved oxygen (DO), watertemperature (WT), transparency (SD), total nitrogen (TN) and nitrate nitrogen ($\text{NO}_3\text{-N}$) from 7 environmental factors such as pH value, dissolved oxygen(DO), watertemperature (WT), transparency (SD), total nitrogen (TN), nitrate nitrogen ($\text{NO}_3\text{-N}$) and ammonium nitrogen ($\text{NH}_3\text{-N}$) as the Network input variables for construct model, and using the concentration of Chlorophyll-a as the Network output variable, we constructed the predicting model of the concentration of chlorophyll-a for Tingxia Reservoir Based on BP Neural Network and the software of Matlab7.0. The results of model output showed that the forecasted value of the concentration of chlorophyll-a according to the BP neural network predicting model had a better fit with actual value of the concentration of chlorophyll-a, and the correlation coefficient achieved 0.768, it indicated the BP neural network predicting model can accurately reflect the trends of the concentration of chlorophyll-a in Tingxia Reservoir. After the model determined, in order to further explore what the input environment variables are the main factor that influence the concentration of chlorophyll-a in Tingxia Reservoir, we carried on sensitivity analysis to the constructed BP neural network predicting model, and the results showed that the pH value and water temperature not only are the main factor that influence the concentration of chlorophyll-a in Tingxia Reservoir, but the main driver factors that influence the growth of algae in Tingxia Reservoir.

2. We monitored the Meihu Reservoir in Cixi city between February 2009 and January 2010 for year. The monitor projects were the same with Tingxia Reservoir. Using the principal component analysis method, we selected 5 environmental factors such as dissolved oxygen, water temperature, total nitrogen, nitrate nitrogen and ammonium nitrogen as the Network input variables for construct model, and using the concentration of Chlorophyll-a as the Network output variable, we constructed the predicting model of the concentration of chlorophyll-a for Meihu Reservoir Based on BP Neural Network and the software of Matlab7.0. The results of model output showed that the forecasted value of the concentration of chlorophyll-a according to the BP neural network predicting model had a better fit with actual value of the concentration of chlorophyll-a, and the correlation coefficient achieved 0.877, it indicated the BP neural network predicting model can accurately reflect the trends of the concentration of chlorophyll-a in Meihu Reservoir. After the model determined, in order to further explore what the input environment variables are the main factor that influence the concentration of chlorophyll-a in Meihu Reservoir, we carried on sensitivity analysis to the constructed BP neural network predicting model, and the results showed that the water temperature and the content not only are the main factor that influence the

concentration of chlorophyll-a in Meihu Reservoir, but the main driver factors that influence the growth of algae in Meihu Reservoir.

3. We monitored the small-scale pond in Ningbo University between March 2009 and October 2010 for 30 weeks. The monitor project including 6 physical and chemical factors that are total nitrogen(TN), total phosphorus(TP), transparency (SD), dissolved oxygen(DO), pH value and water temperature(WT) and the biomass of phytoplankton, especially the density of *Oscillatoria*. We used the monitored data of the (n-1) week and the (n-2) week of 6 environmental factors as the Network input variables for construct model, and used the monitored data of the n week of the density of *Oscillatoria* as the Network output variable, then we constructed the predicting model of the algae blooms for the small-scale pond in Ningbo University Based on BP Neural Network and the software of Matlab7.0, and made the short-term forecast to the density of *Oscillatoria* of the small-scale pond, and sensitivity analysis was performed to the model. The results showed that the forecasted value of the density of *Oscillatoria* according to the BP neural network predicting model had a better fit with actual value of the density of *Oscillatoria*, and the correlation coefficient achieved 0.984, it indicated the BP neural network predicting model can be used for short-term forecast of the algal blooms; and through carried on sensitivity analysis to the constructed BP neural network predicting model, it clarified the main driver factor of algal blooms in the School pond of Ningbo University, and the result showed that controlling PH value would be important to prevent and control the algal blooms in the School pond of Ningbo University.

4. According to the 30 weeks of monitored data from March to October in 2009 in the School pond of Ningbo University, and the hydration and biological indicators, we used multivariate statistical analysis such as MDS, CLUSTER to deal with the relation between the phytoplankton community structure and environmental factors based on PRIMER 5.0 multivariate statistical analysis software of community structure. The results showed that the advantage of algae are cyanobacteria and green algae in the sampling pond, the prosperous process is divided into three stages of green algae, green and blue-green algae, blue-green algae, and there is a community succession process of two advantages of algal. Through the results of RELATE and BIO-ENV correlation analysis between the entire phytoplankton community, the cyanobacteria phytoplankton community and environmental factors in the sampling pond, the entire phytoplankton community and environmental factors is significantly correlated ($p=0.1\%$) with correlation coefficient of 0.489, while the cyanobacteria community and environmental factors is significantly correlated ($p=0.1\%$) with correlation coefficient of 0.449, the correlation between the two communities and the environmental factors of ponds is extremely significant, and the two environmental factors of SD and PH are the best combination of environmental factors of the entire phytoplankton community, while SD, pH and WT are the best combination of environmental factor of the cyanobacteria

community. In addition, PH is the key control factor to both the entire phytoplankton community and the cyanobacteria community, and the correlation coefficient between the pH and entire phytoplankton community achieved 0.711.

Key Words: PHytoplankton, the concentration of chloropHyll-a, BP neural network, predicting model, Community structure, Multivariate statistical analysis

目 录

引 言	1
1 文献综述	3
1.1 水体富营养化和藻类水华	3
1.2 水体浮游藻类发生动态研究	4
1.2.1 浮游藻类的研究意义	4
1.2.2 环境因子对浮游藻类的影响	4
1.2.3 浮游藻类的动态变化研究	5
1.3 水体浮游藻类预测模型构建	7
1.4 本研究的意义	11
2 水库浮游藻类发生动态及预测模型构建—亭下水库	13
2.1 材料和方法	13
2.1.1 样品采集	13
2.1.2 水样的测定与分析	14
2.1.3 数据分析方法	15
2.2 结果	17
2.2.1 亭下水库主要理化因子	17
2.2.2 浮游藻类	19
2.2.3 亭下水库叶绿素 a 浓度预测模型构建	20
2.3 讨论	27
2.3.1 BP 神经网络预测模型结果分析	27
2.3.2 影响亭下水库藻类生长的主要驱动因子	27
2.4 小结	28
3 水库浮游藻类发生动态及预测模型构建—梅湖水库	29
3.1 材料和方法	29
3.1.1 样品采集	29

3.1.2	水样的测定与分析	30
3.1.3	数据分析方法	30
3.2	结果.....	30
3.2.1	梅湖水库主要理化因子.....	30
3.2.2	梅湖水库浮游藻类种类组成.....	32
3.2.3	梅湖水库叶绿素 a 浓度预测模型的构建.....	33
3.3	讨论.....	39
3.3.1	BP 神经网络预测模型结果分析	39
3.3.2	影响亭下水库藻类生长的主要驱动因子.....	40
3.4	小结.....	40
4	藻华浮游藻类发生动态及预测模型构建—校内池塘	41
4.1	研究对象和方法.....	41
4.1.1	采样池塘概况	41
4.1.2	BP 人工神经网络方法.....	41
4.2	数据采集	41
4.3	采样池塘浮游植物种类组成及其丰度变化	43
4.4	模型的设计、选择及验证	45
4.4.1	模型数据集的选取及处理.....	45
4.4.2	模型的构建及选择	46
4.4.3	模型的敏感度分析	47
4.5	结果与讨论	47
4.5.1	训练获得的神经网络及其验证	47
4.5.2	敏感度分析结果	49
4.6	小结.....	50
5	藻华水体浮游植物群落结构的研究—校内池塘.....	51
5.1	材料与方法	51
5.1.1	采样池塘基本情况	51
5.1.2	样品采集和测定	51

5.1.3 数据处理方法	51
5.2 结果与分析	52
5.2.1 采样池塘环境因子的变化.....	52
5.2.2 采样池塘浮游植物种类组成及其丰度变化.....	52
5.2.3 采样池塘浮游植物群落结构及其与环境因子的关系.....	52
5.3 小结与讨论	57
6 总结与展望.....	58
6.1 本研究的创新之处.....	58
6.2 研究展望	59
在 学 研 究 成 果.....	68
致 谢.....	70

引 言

随着工农业的快速发展,大量营养物质随地表径流等排入水体,导致水质污染和水体富营养化现象日益严重。据联合国环境规划署的一项调查,在全球范围内 30%—40%的湖泊和水库受到了不同程度的富营养化的影响。我国江河、湖泊和水库众多,多年以来的调查结果表明,我国富营养型化湖泊个数占调查湖泊总数的比例,由 20 世纪 70 年代末的 41%发展到 80 年代后期的 61%,至 20 世纪 90 年代后期又上升到 77%。据统计,在 2001 年我国发生富营养化的水体,超出了国际平均水平(张维昊等,2001)。

水体的富营养化不但直接危害渔业生产和水资源的利用,严重影响工农业生产的可持续发展,并且为藻类的发生和长期维持提供了较为良好的基础条件,这样,藻类在越来越多的湖泊、河流和海域中发生,并长期维持,对水生生态系统的平衡、人类的生活和生产都构成了严重的威胁。目前,我国境内的许多湖泊(Liu *et al*,1995; 赵影等,2002; 张哲海,2006; 奚万艳等,2007)、水库(刘家寿等,2001; 方云英等,2004; 金春华等,2005, 苏玉萍等,2006)和河流(卢大远等,2000; 周广杰等,2006)都有水华发生的报道。因此,藻类问题对国内多数水体而言都是已经或是即将面临的主要问题。藻类的爆发,尤其是蓝藻的爆发已经成为全球关注的重大环境问题之一。蓝藻的形成在影响水生生态系统协调与稳定的同时,其次生代谢产物-藻毒素对多种有机体甚至人类的毒性倍受关注。微囊藻产生的微囊藻毒素(MC)是分布最广,毒性最大的种类之一,因其可导致水生和一些陆生动物中毒,并可通过饮用水和食物链等途径直接威胁人类健康,使藻类的预报和防治成为研究的热点之一。

国内外对于浮游藻类发生动态和预测模型的构建已经有了一些研究(Saowapa *et al*,1997; 梅卓华等,2010; Hou *et al*,2004;Maier *et al*,1998),但由于不同水域的特殊性,尤其对于亚热带水域的不同内陆水体,将浮游藻类发生动态和预测模型构建相结合,对浮游藻类水华进行应急监测和预报预警方面的研究很少且不系统。尤其对预测模型构建过程中模型输入变量的选择以及模型中隐含层节点数的选择问题等研究还不够深入。浮游藻类的预测模型应该如何构建?选择何种方法来构建?预测模型的输入变量如何选择?模型中的隐含层节点数如何选择?不同的水域有何区别?这些问题均有待更

为系统和全面的研究予以解答。为此，本研究选取了位于亚热带地区的两种不同类型内陆水体（包括两个具有代表性的饮用水水库和一个小型藻华池塘），以对水体连续进行跟踪监测的实测数据作为研究浮游藻类动态变化以及藻华预测模型构建的现场证据，分析浮游藻类的变化规律以及与水体环境因子之间的关系，并利用主成分分析等统计方法，选出影响浮游藻类动态变化的主要水体环境因子，并作为预测模型构建时的输入变量，再利用人工神经网络方法来构建浮游藻类的预测模型，以期进一步完善浮游藻类应急监测、预警和应急处理方法体系，提高对浮游藻类应急监测及预防处置的能力，有效预防浮游藻类的发生提供更为科学的依据。

1 文献综述

1.1 水体富营养化和藻类水华

水体的富营养化，通常是指由于人类的活动使水体中氮、磷等外源营养物质大量进入，引起藻类及其他生物迅速繁殖，水体溶解氧状况恶化，水质下降，从而导致鱼类及其他水生生物大量死亡的现象。早在十年以前，欧洲、非洲、北美洲和南美洲已分别有 53%、28%、48% 和 41% 的湖泊存在不同程度的富营养化现象，亚太地区 54% 的湖泊处于富营养化状态（Ingrid *et al*, 1999），我国则在 60% 以上（张维昊等，2001）。除了云南滇池、江苏太湖和安徽巢湖三大淡水湖泊已发生严重的蓝藻水华污染外，长江、黄河中下游的许多湖泊和水库中也相继发生了不同程度的蓝藻水华污染现象。天然水体富营养化已成为我国乃至世界所面临的重大环境污染问题之一。水体富营养化在池塘、水库、湖泊等多发。一般认为水体全氮量大于 0.2mg/L、全磷量大于 0.02mg/L 时属于富营养化水体。美国环境保护局（EPA）提出：水体总磷大于 20-25g/L，叶绿素 a 大于 10g/L，透明度小于 2.0m，深水的饱和溶解氧量小于 10% 的湖泊可判断为富营养化水体。

藻类水华是水体中的一种自然现象，可由多种藻类引起，如蓝藻（严格意义上应称为蓝细菌）、绿藻、硅藻等。发生时，水一般呈蓝色或绿色或赤色等。这种在自然界就有的现象，在我国古代历史上就有记载。发生后如果很快消失，则不会给水产动物和人类带来危害。但是，人类进入现代社会之后，由于严重的环境污染，尤其大量农业、工业、生活废水进入水体导致水体（包括湖泊、水库、河流和海洋）都出现了不同程度的富营养化，并导致了水华的发生和长期蔓延。藻类水华是水体富营养化的重要表征，而藻类水华的发生又进一步加剧了水体的污染（Codd, 2000），这样，藻类水华在越来越多的湖泊、河流和海域中发生，并长期维持，造成了水体缺氧，水生动物的死亡，水生态系统失衡，特别是蓝藻水华，对水体的危害性更大，部分蓝藻水华种类能够产生藻毒素，影响水体其他生物的正常生活，甚至对水禽、家畜以及人类产生严重危害；有些蓝藻水华种类能产生异味物质，影响自来水的品质（Sugiura *et al*, 2004）；此外，藻类水华的形成，破坏了水体景观。

1.2 水体浮游藻类发生动态研究

1.2.1 浮游藻类的研究意义

水体浮游藻类是水体初级生产力的主要贡献者，为鱼类、大型草食动物、浮游动物提供生存所必需的食物，在食物链中起着重要作用，同时也影响着水体的水质状况（潘继征等，2009），浮游藻类启动了淡水生态系统的物质循环和能量流动，在水生态系统的物质循环、能量流动和信息传递中起着至关重要的作用（李敦海等，2007；张婷等，2006；孙军等，2004），是淡水生态系统中最基础的一环。浮游藻类的繁殖与水体营养状态关系密切，浮游藻类大量繁殖可以形成水华，造成水体富营养化，水质功能下降，但浮游藻类作为一种自养型生物，可以通过光合作用利用水体中的氮、磷等元素，从而降低了水体中氮、磷等营养物质的含量。另外，浮游藻类也可以通过光合作用向水体提供溶解氧，对水体理化条件的改善起到了一定的作用，并且浮游藻类能够利用水体中的微生物分解有机物产生的二氧化碳和其他产物，达到“藻菌共生”，从而在水体的净化过程中发挥了极其重要的作用（沈韞芬等，1990）。同时，浮游藻类种类组成、数量分布及丰度的季节性变化，是浮游植物群落动态的重要特征，也是判断水体富营养化程度的关键指标之一（刘娅琴等，2010；赵孟绪等，2005；许金花等，2007），对水体的富营养化和藻类水华的发生起着重要的指导作用。

1.2.2 环境因子对浮游藻类的影响

浮游藻类与其生存的环境是相互依存、相互影响的统一体，浮游藻类的生长、消亡及演替过程要受到温度和营养盐等多个主要水环境因子的影响。

温度对浮游藻类的影响较大，大多数浮游藻类的最适生长温度在 18-25℃ 之间，但不同的浮游藻类有不同的最适温度，如金藻、硅藻更适宜在较冷的水温下生长发育，往往在温度较低的早春、晚秋和冬季较多出现，并占据浮游藻类的优势地位；蓝藻则更适宜在温暖的水体中生长，因此，在温度较高的夏季出现较多（Tilman *et al*, 1984），而绿藻更适宜在中等水温下生长，在中等水温下绿藻占优势。谭啸等（2009）通过研究升温过程对藻类复苏和群落演替的影响，得出藻类群落组成随着温度的升高而逐步发生变化，绿藻在 12.5℃ 和 16℃ 时占优势，而蓝藻在 19.5℃ 以后逐步取得优势，且蓝藻在复苏后的生长速率高于绿藻，并最终导致蓝藻水华的发生。

浮游藻类与营养物质的关系是一个较为复杂的问题，浮游藻类的生长要受到营养盐的调节，在一定浓度范围内，营养盐可促进浮游藻类的生长。但如果营养盐浓度过低，则会限制浮游藻类的生长，反之，水体营养盐的浓度过高，则会引起水体的富营养化（刘东艳，2002）。

Brzezinski（1992）在文章中指出浮游藻类生长需要碳、氮、磷等必须元素，对浮游藻类生长来说，当总氮质量浓度与总磷质量浓度之比在 20:1 以上时，表现为氮过量，磷成为限制因子，浮游藻类种群密度的峰值主要受磷含量的影响；而当氮磷比小于 13:1 时，表现为氮不足，氮成为限制因子，浮游藻类种群密度的峰值主要与氮含量有关。氮和磷是浮游藻类生长所必需的营养元素，随着水体的富营养化，水体中氮磷浓度不断增加，促进了浮游藻类的繁殖。Klausmeier *et al*（2004）以及 Redfield（1958）在文章中指出，浮游藻类健康生长及生理平衡所需的氮磷比率为 16:1。水体氮磷营养供应及其比率对浮游藻类的种群结构有重要的决定作用（Michael *et al*,2002;Nydicke *et al*,2004;Pick,1989;曲克明等,2000;Tilman *et al*,1982）。

1.2.3 浮游藻类的动态变化研究

浮游藻类的动态变化主要是指浮游藻类随时间和空间的变化规律及其演替过程，浮游藻类中的蓝绿藻由于多具有趋光性以及运动能力等特点，很容易在局部水域中大量聚集，并形成很高的密度，最终导致藻类的发生，发生后，部分藻类就会产生一些毒素，就算是在藻类密度很低的情况下，毒素的毒性也会经过摄食动物摄食进入食物链进行富集，对人类的健康产生了诸多危害（林金美等，1988）。因此，在浮游藻类的生态学研究，浮游藻类的演替过程作为一个非常重要领域而被探讨，尤其是在人类活动干扰比较多的环境中。

浮游藻类群落是一个运动着的体系，时刻在不断地变化着，在外界环境条件变化的影响下，浮游藻类群落的组成和结构会发生变化。从生态学角度来看，浮游藻类的演替过程是随着水体的水流、pH 值、溶解氧、温度、盐度、营养盐的补充循环等诸多环境因素的变化而变化的一种自然现象。齐雨藻等（1994）及朱从举等（1994）指出浮游藻类的群落演替不是一个只随季节而变化的周而复始的简单循环过程，其演替过程必将受到一些特殊环境因素的诱导。

浮游藻类群落的演替类型主要有两种，一种是顺行演替；另一种是逆行演替。顺行演替是指在自然状态下，浮游藻类群落的演替过程，其群落种类

由贫乏逐渐多样化，结构由简单而繁，随着生存空间的扩展，环境向着适宜于多种生物生存的方向变迁，这是群落演替的根本趋势，这种演替就成为顺行演替；与此过程相反的演替称为逆行演替。要是有一个群落处于逆行演替状态，它的种群组成和结构将日趋简化，生存环境也朝着逆行方向发展。植物群落与其生存环境是相互协调的统一整体（Eugen,1983; Daubenmire,1977）。一定的生存环境是一定类群存在的前提，群落生活过程导致环境的演化，同时环境的演化也会影响到群落的生活过程，两者互为因果，协同发展。如果生物类群和环境之间的这种协调关系被破坏，会造成群落组成与结构的破坏，最终引起逆行演替的发生，同时，生物群落的生存环境亦不可避免的发生退化。

浮游藻类群落演替反映了浮游藻类与其生存环境之间的动态关系，雷安平等（2003）通过对武汉东湖浮游藻类物种多样性的研究指出植物群落演替是一个复杂的过程，植物群落演替最明显的特征是优势种的演替。影响浮游藻类演替的因素主要有以下几种：（1）水体的富营养化。水体的富营养化使得水体中营养物质增加，合适的营养比例满足了浮游藻类大量繁殖所需的营养物质，浮游藻类在合适的水环境下大量繁殖，数量急剧增多，常常导致水华的发生，引起水质恶化。（2）浮游藻类的代谢物以及分解物。一些浮游藻类代谢分泌相生相克的物质以及藻类死亡后分解的物质限制了水体中其他浮游藻类的正常生长和繁殖，使得这些浮游藻类在竞争中处于优势地位，从而在水体中占据统治地位。关于浮游藻类之间的竞争关系，Holm&Armstrong（1981）报道了水体中硅藻和微囊藻种间的相互作用，认为硅元素的减少，其他营养物质的增加是导致微囊藻取代硅藻并成为优势种的重要因素。另外，我国的刘世枚等（1991）也对水体中两种蓝藻种群间的相互作用进行了研究。（3）水体的污染程度。由于水体的污染不断加剧，使得原本在自然条件下竞争能力强的优势物种的竞争能力降低了，导致生物类群发生逆行演替。因此，研究水体中浮游藻类之间的竞争关系及影响竞争关系的因素，都会对研究富营养化过程中浮游藻类群落演替规律和机制具有重要的指导意义。

水体中浮游藻类发生动态的研究，能够为水体富营养化和藻类的有效防治提供科学依据，目前，已有许多学者对其进行了研究。吴生才等（2004）于2002年定点观测了太湖梅梁湾水体5个层位上的悬浮质和叶绿素含量，同

时比较了太湖近六年的叶绿素和悬浮质检测结果，并且将叶绿素及其与悬浮质的比值的平均数作为对生物量的衡量指标，并在文中讨论了太湖水体中生物量波动周期与多种环境因子之间的相关性。研究表明，湖泊生物量的周年变化与湖泊的深度和营养状况密切相关，营养状况决定了在物理因素达到最佳时所能得到的最大生物量，湖泊的深度影响营养盐内循环的速度和效率。吴玉霖等（2004）应用分光光度法对青岛胶州湾浮游植物数量的长期动态变化进行了研究，研究主要是针对胶州湾 1991—2002 年 11 月浮游植物现存量（叶绿素 a 含量）进行的。孙凌等（2006）选取天津市小型人工湖湖水样品，调整氮磷起始质量比（分别为 0.5: 1、7.2: 1、25: 1、50: 1），在水族试验箱内进行生态模拟试验，探讨了在不同氮磷比条件下城市湖水浮游藻类对不同氮磷比的响应。并着重指出了试验水体中蓝藻和绿藻在不同氮磷比条件下的变化，研究表明，富营养化的水体中，当氮磷比例较低时，将会出现绿藻的大量繁殖，而出现绿藻类的高峰，当氮磷比例较高时，绿藻的生长竞争不过蓝藻，蓝藻大量繁殖，而出现蓝藻累的高峰。张志兵等（2009）于 2006—2007 年对杭州西湖浮游藻类的种类及个体丰度进行了初步研究，并根据《水和废水监测分析方法》对其水质现状进行了生物学评价，分析了杭州西湖浮游藻类的组成和分布的特点，揭示出西湖浮游藻类的种类组成与西湖水质变化之间的关系。结果表明，浮游藻类的组成和分布与水质变化规律是基本吻合的。陈立婧等（2008）于 2004 年 4 月—2006 年 1 月对江苏太湖的浮游藻类进行了调查，分析了浮游藻类的群落结构、物种多样性以及对浮游藻类与太湖理化参数的相互关系。为了进一步研究浮游藻类的动态变化，裴洪平等（2000）构建了杭州西湖浮游藻类的动态模型。

1.3 水体浮游藻类预测模型构建

面对水体富营养化和浮游藻类水华问题，目前已经有许多研究人员试图通过构建浮游藻类的预测模型来进行仿真，通过研究浮游藻类生物量和环境因素的相互关系，确定浮游藻类生物量的变化规律以及藻类水华的发生机理，并利用一定的技术来构建藻类预测模型，并采取应对措施来减轻藻类水华可能带来的损失。对藻类水华预测模型的研究主要有两种方法：一种是基于过程的确定性机理模型；另一种是基于大量历史数据的归纳模型。

基于过程的确定性机理模型是以现实系统的基本物理、化学定律理论和知识构造简化模型为基础而得到的预测模型。Bierman（1976）利用食物链和藻类生理学相关知识构建了浮游藻类种群生物量富集过程的预测模型。

Reynolds (1984) 利用 12 个温带湖泊 49 个不同藻类种群的生物量数据构造了一个列线图 (Nomogram)，并用这个列线图来解释藻类种群的生物量变化。

基于大量历史数据的归纳模型方法是基于大量的历史数据，并利用回归分析和相关分析等统计方法从中抽取知识和模式来构造系统的整体预测模型。Dillon (1975) 和 Sakamoto (1966) 构造了第一个实证数据模型，并利用水体中总磷的数据来预测湖泊中叶绿素 a 的浓度。Whitehead 等 (1984) 基于时间序列方法构造了一个预测模型，并对泰晤士河中叶绿素的数量变化进行了预测。Recknagel 等 (1994) 基于模糊逻辑方法构建了预测模型并用于预测湖泊和水库中叶绿素的数量变化。对赤潮的研究，我国的黄良民等 (1994)、赵明桥等 (2003) 和谢中华 (2004) 基于回归分析方法对水体中环境变量和赤潮的关系进行了研究。刘元波等 (2000) 以过程模拟研究为主线，从浮游藻类生长与吸收、生态过程、尺度与空间异质性等方面阐述了湖泊浮游藻类动态模拟研究的发展态势与存在问题，认为结构动力学模型、生态与水动力耦合模型、面向对象模型和神经网络模型等具有良好的发展前景。此外，模糊逻辑作为一种常用于复杂系统建模和预测的数学方法 (Altrock, 1995; Czogala, 2000)，也开始用于藻类水华预测模型的构建 (Chen et al, 2002; Soyupak et al, 2004; Marsili, 2004)。

人工神经网络 (Artificial Neural Networks, 简称 ANNA) 是基于模仿人体大脑神经网络网络结构和功能而建立起来的一种高度复杂的非线性的动力学信息处理系统 (阎平凡, 2000)。该系统具有应用工程技术、计算机手段模拟生物神经网络的结构和功能，实现知识并行分布处理，是一个人工智能信息处理系统，并且具有较高的构建模型能力和良好的数据拟合能力。人工神经网络除了具有一般非线性系统的共性，更主要的是具有高维性、神经元之间的广泛互联性、自适应性和自组织性，人工神经网络正是由于具有这些独特的结构特点，才使其具有高度的并行性和很强的容错能力和学习能力。目前，对人工神经网络的应用已经渗透到各个领域，并在信号处理、模式识别、非线性优化等方面取得了重大进展，并且该方法日益成熟，具有重要的理论和应用价值 (杨建刚, 2001)。代表性的人工神经网络有 EBP 网络 (反向传播算法)、Hopfield 网络模型、随机型神经网络、自组织神经网络、联想记忆神经网络、CMAC 模型和遗传算法等类型的网络。

随着人工神经网络应用的兴起, 人工神经网络已被开始应用于藻类生态预测模型的构建。French 等 (1994) 利用藻类生物量和环境变量的历史数据, 应用人工神经网络构建了藻类种群生物量变化的预测模型。Waiter 等 (2001) 基于人工神经网络中的反馈神经网络方法和一种推理型的确定性模型 SALMO 对澳大利亚 Burrinjuck 水库的总藻生物量变化进行了预测。结果表明: 基于反馈神经网络方法构建的预测模型更擅长于短期预测, 并能够对藻类水华的发生进行有效的预报预警。Jeong 等 (2001) 基于人工神经网络中的反馈神经网络方法对韩国的 Nakdong 河以及下游水库的藻生态进行了建模, 并对水体中的铜绿微囊藻等几种藻类以及总藻生物量进行了预测。预测模型结果显示网络输出值和实测值之间的相关系数达到了 0.8 以上, 两者的拟合程度较好, 能够实现对藻类水华的有效预报预警。邬红娟等 (2001) 利用辽宁大伙房水库 1980-1997 年的水文和湖沼学观测数据, 基于人工神经网络方法构建了水库浮游植物丰度和蓝藻优势度的预测模型, 并对构建的预测模型进行了检验。结果表明, 基于人工神经网络方法构建的预测模型优于传统的统计学模型, 可对水库中浮游植物群落进行预测预报, 并具有较高的精度。

人工神经网络方法不仅被应用于淡水藻类生态预测模型的构建中, 而且对海洋赤潮的预测中也被广泛应用。孙蓉桦等 (2005) 基于人工神经网络中的通用回归神经网络 (General regression neural network) 方法构建了赤潮预报的预测模型。Zhang 等 (2006) 也利用人工神经网络中的模糊神经网络对赤潮进行了预报预警。

BP 人工神经网络的全称为 Back-Propagation Network, 即反向传播网络。BP 网络是一个前向多层网络, 具有很强的学习能力和记忆力, 它利用误差反向传播算法对网络进行训练, 包含了神经网络理论中最为精华的部分。由于其结构简单、可塑性强, 故在函数逼近、模式识别、信息分类及数据压缩等领域得到了广泛的应用。由于它的数学意义明确, 学习算法步骤分明, 使得应用背景更加广泛。

BP 人工神经网络方法在工程、社会、经济、金融等诸多领域都得到了广泛应用 (Celik *et al*, 2007; Engin *et al*, 2007; Grznar *et al*, 2007; Ráduly *et al*, 2007; Zou *et al*, 2007)。同时, BP 人工神经网络作为人工神经网络中最为常用的网络结构之一, 已经被广泛的应用于水生态系统中预测模型的构建中。Recknagel 等 (1997) 基于日本的 Kasumigaura 湖、Biwa 湖, 芬兰的 Tuusulanjaervi 湖, 以及澳大利亚的 Darling 河的大量历史数据, 利用 BP 人工

神经网络方法，以水体中的营养物水平、pH、光强等气候因素、气温、以及河流流量等环境变量的历史数据作为 BP 网络的输入变量，以水体中总藻生物量作为 BP 网络的输出变量，构建了预测模型。预测结果显示 BP 网络输出值与实测值之间有一定的误差，但预测结果基本上能够反映藻类种群生物量的高峰和低谷。Yabunaka 等（1997）应用 BP 人工神经网络，基于日本第二大湖，Kasumigaura 湖 1981-1992 年的历史监测数据，构建了水体中微囊藻和颤藻等 5 种藻以及叶绿素浓度的预测模型。预测结果表明，构建的 BP 网络模型能够较好地预测微囊藻的生物量变化以及微囊藻水华发生的时间和强度，并且能够较好的预测叶绿素浓度的变化，但对另外四种藻类的生物量变化的预测效果不太理想。Wei 等（2001）也应用 BP 人工神经网络方法，基于 Kasumigaura 湖 1982-1996 年的历史监测数据，并以 WT、SD、pH 值、DO、COD、TN、TP 和浮游动物的密度共 8 个环境变量作为 BP 网络的输入变量，以 *Oscillatoria*、*Microcystis*、*Synedra*、*Phormidium* 四种藻的生物量作为 BP 网络模型的输出变量，构建了 Kasumigaura 湖藻生态的预测模型，预测模型输出结果显示，模型对微囊藻水华发生的时间和强度变化有很好的预测，能够较好的预测 *Phormidium* 和 *Synedra* 两种藻的生物量变化，但对颤藻生物量的预测结果不太令人满意。Maier&Dandy（1997）以及 Maier 等（1998）应用 BP 人工神经网络方法，以澳大利亚 Murray 河的水文、气候、营养物水平等因素的历史数据作为网络模型的输入变量，以 *Anabaena* 藻的生物量变化作为网络模型的输出变量，构建了河流的藻生态模型，该预测模型能够较好的捕捉 *Anabaena* 藻水华的高峰。Joseph 等（2003）应用人工神经网络中的 BP 人工神经网络方法，基于香港 Tolo 海湾 1982-2000 年全双周水质监测数据和 Lamma 海岛 1996-2000 的每周生物量的监测数据，构建了香港海岸水体藻类水华的动力学模型。文中指出先前利用人工神经网络构建藻类动态模型时将“将来数据”用于网络是错误的。并且还用 Lamma 的监测数据进行了实时预测，研究结果表明，用小部分输入变量也可以获得藻类的动态变化趋势，但对数据的采样时间间隔要一周一次。Kunwar 等（2009）应用 BP 人工神经网络，利用印度 Gomti 河 10 年的跟踪监测数据，以 pH 值、化学耗氧量、钠、钾等 11 个环境变量作为网络模型的输入变量，以 DO 和 BOD 作为网络模型的输出变量，分别构建了 DO 和 BOD 的预测模型，并用相关性系数和均方根误差来评价所构建的网络模型。

国内的许多学者也应用 BP 人工神经网络构建了藻生态的一些预测模型。林佳等（2007）应用 BP 人工神经网络方法，基于福建省山仔水库 2003-2006 年叶绿素 a 浓度、DO、TP、TN、pH 值、WT、高锰酸盐指数 7 个参数监测数据作为 BP 网络模型的输入变量，并用 1997-2002 年除叶绿素 a 浓度外其他 6 个参数监测数据，推算出 1997-2002 年间缺失的叶绿素 a 浓度，对 1997-2006 年春末夏初的叶绿素 a 浓度的动态变化进行了分析，该预测模型的构建为山仔水库富营养化的治理提供了科学依据。裴洪平等（2004）利用西湖 2000 年 1 月至 4 月常规监测数据，基于 BP 人工神经网络方法，并利用插值的方法使其生成足够多的样本数，构建了西湖叶绿素 a 浓度的预测模型，模型输出结果显示，叶绿素 a 含量和 WT 对未来一周的叶绿素 a 含量影响最大，以这两者作为输入变量建立的网络简单、快捷，优于其它的线性插值模拟预测方法，可为西湖富营养化治理提供科学依据。邱靖等（2007）运用神经网络理论和方法，建立了基于三层 BP 网络的预测模型，并对 BP 算法进行了改进。并就长江流域丰水期全流域的水质情况进行模拟比较，确定了该模型的隐含层节点数以及实用范围，并能较精确地预测今后 5 年的发展趋势，且预测结果客观。证明了构建的 BP 网络预测模型具有较强的泛化能力，是一种行之有效的预测非线性类问题的模型。刘建萍等（2009）应用 BP 人工神经网络方法，根据太湖 2005 年的监测数据，以水深、水温、营养盐等 10 项环境因子作为网络模型的输入变量，以太湖叶绿素 a 浓度作为网络模型的输出，构建了太湖叶绿素 a 浓度的预测模型，并用多元统计回归方法建立了模型，结果表明，BP 神经网络模型优于传统的多元统计回归模型。

1.4 本研究的意义

水体富营养化问题是目前全球性最大且最为普遍的淡水资源保护问题之一。近年来，经济的发展加速了水体富营养化，因浮游藻类过度生长而引起的藻类水华，已经给国民经济和人民生活造成了极大的危害，尤其对饮用水安全带来了严重的威胁。因此，迫切需要识别浮游藻类群落结构的变化规律及其影响因子并对其进行准确的预测或预报，以达到有效控制藻类水华的目的。

浮游藻类群落作为水域生态系统的初级生产者，在食物链中起着重要作用，同时也影响着水体的水质状况（潘继征等，2009）。研究一个水体的浮游藻类群落结构及其发生动态是了解水体生态系统结构的基础。浮游藻类种类组成、数量分布以及丰度的季节性变化，是浮游植物群落动态的重要特

征，也是判断水体富营养化程度的关键指标之一（刘娅琴等，2010；赵孟绪等，2005；许金花等，2007），对藻类水华的发生起着指导作用，因此，研究水体浮游藻类群落结构的动态变化也是水域生态学的重要内容。

目前国内外在水体富营养化及蓝藻水华发生机理、蓝藻治理等方面开展了大量的研究工作，也取得了一定得成果，但针对藻类水华的预测、预警体系尚不完善，应急处置能力普遍薄弱，严重制约了预防处置藻类水华污染事件能力的提升。

本文以监测、分析 2 种不同类型内陆水体浮游藻类组成、特征及其影响因素在时空尺度上的变化为基础，采用人工神经网络方法对浮游藻类动态变化与环境因子的关系进行识别和预测，以期通过浮游藻类预测模型的构建，对藻类水华的发生起到预测预警作用，为有效预防和处置藻类水华提供帮助。

2 水库浮游藻类发生动态及预测模型构建—亭下水库

亭下水库位于浙江省奉化市境内，距宁波市 47km，距溪口镇 6km。水库坝高 76.5m，总库容 1.53 亿 m^3 ，集雨面积 176km^2 ，主流长度 34.6km，是一座以防洪、灌溉为主，综合发电、供水等综合利用的大型水利工程。本研究在总结水库浮游藻类组成及其动态变化的基础上，利用主成分分析（PCA）等统计方法，找出影响浮游藻类动态变化的主要水体环境因子，再应用 BP 人工神经网络方法，构建浮游藻类的预测模型。

2.1 材料和方法

2.1.1 样品采集

根据亭下水库的自然地理特征，在亭下水库布设 3 个具有代表性的采样点（图 2.1），其中 1#采样点位于水库大坝坝前；2#采样点位于水库中段；3#采样点位于水库的上游。于 2009 年 2 月至 2010 年 1 月期间，对水库水体每月跟踪监测 1 次，共采样 12 次。

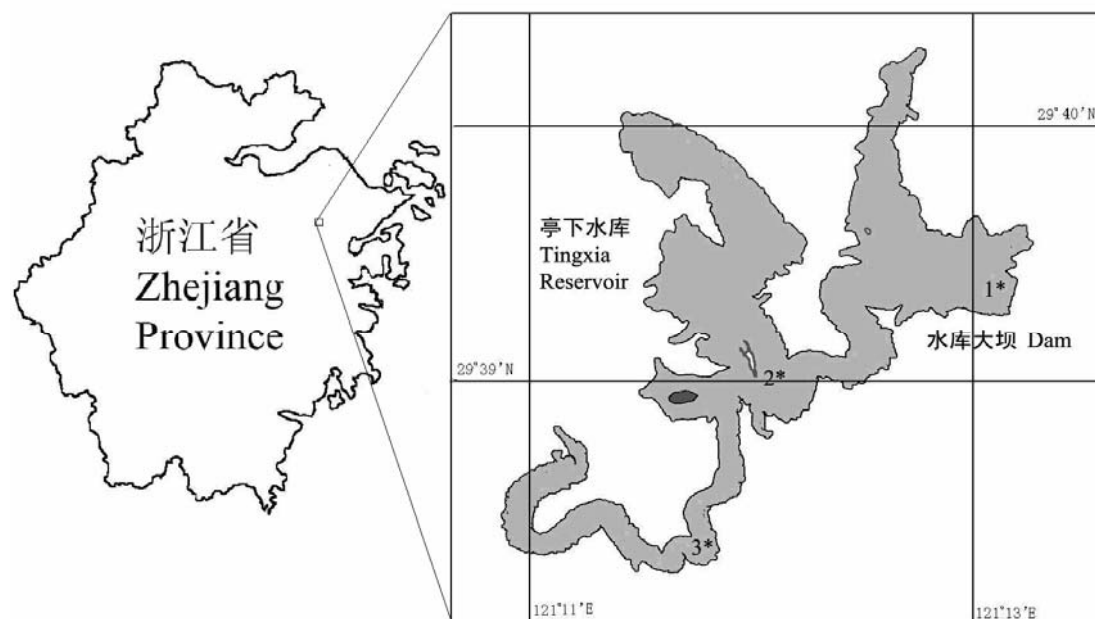


图 2.1 亭下水库采样点布设图 *采样点

Fig.2.1 Map of Tingxia Reservoir with three Sampling sites * Sampling sites

采样过程中，1#采样点分别采取表（离水表层 0.5m）、中、底（离水底 0.5m）三层水样，2#采样点和 3#采样点只采取表层（离水表层 0.5m）水样。各采样点均用 5L 采水器采取水样，浮游植物样品取水样 1L，放入定容的塑料瓶中，采得后立即加入 15ml 鲁哥氏液（Lugol's solution）固定（鲁哥氏液

配制方法：将 6g 碘化钾溶于 20ml 水中，待其完全溶解后，加入 4g 碘充分摇动，待碘全溶解后加入 80ml 水即可）。浮游动物样品按每个采样点取水样 10L，现场用 25 号浮游生物网过滤，浓缩样品集中于 500ml 的塑料瓶中，并加入 7ml 甲醛固定。用于测定水化学指标的水样，在各采样点按各采样点的采集方法采集，带回实验室测定。

2.1.2 水样的测定与分析

现场用 Hydrolab Datasonde 4 α 水质分析仪测定 WT、pH 值和 DO，Bbe FluoroProbe 叶绿素水下荧光分析仪测定 Chl-a 浓度，Secchi 盘测定透明度 SD。TN 用碱性过硫酸钾消解紫外分光光度法，水体中 NO₃-N 和 NH₃-N 的含量在实验室通过全自动化学间断分析仪仪器测定。

浮游植物定量水样先放入 1000mL 分液漏斗中，静置 48h 后，用内径为 30mL 的橡皮乳胶管，接上橡皮球，利用虹吸法将沉淀上层清液缓慢吸出，剩下 50mL 沉淀物，倒入定量瓶中以备计数（金相灿等，1990）。

将浓缩沉淀后水样充分摇匀，吸出 0.1mL，置于 0.1mL 浮游植物计数框内（表面积 20×20mm²）在 16×40 倍光学显微镜（NOVEL XS-2100）下观察计数，每瓶标本计数二片取其平均值，每片计数视野数按浮游植物多少酌情增减，每片计数的细胞总数控制在 1000-2000 个以内，同一样品的二片计算结果和平均数之差如不大于其均数的 15%，其均数视为有效结果，否则还测第三片，直至三片平均数与相近二数之差不超过均数的 15% 为止，这两个相近的值的均数，视为计数结果（金相灿等，1990）。

计数过程中如某些细胞个体的一部分在视野中，而另一部在视野外，规定在视野上半圈者计数，下半圈者不计数。数量用细胞数表示，对不可用细胞数表示的群体或丝状体，求出其平均细胞数（金相灿等，1990）。计数时优势种类鉴别到种，其余尽可能鉴别到种。浮游生物的鉴定主要参见文献（章宗涉和黄祥飞，1991；韩茂森和束蕴芳，1995；胡鸿钧和魏印心，2006），其中微囊藻属主要参照（虞功亮等，2007）。

1L 水中的浮游植物的数量（N）计算公式：

$$N = \frac{C_s}{F_s \times F_n} \times \frac{V}{U} \times P_n \quad (\text{公式 2.1})$$

式中： C_s ：计数框面积（ mm^2 ）； F_s ：每个视野的面积； F_n ：计数过的视野数； V ：1L 水样经沉淀浓缩后的体积（mL）； U ：计数框体积（mL）； P_n ：每片计数出的浮游植物个数。

1L 水中的浮游动物的数量（ N ）计算公式：

$$N = \frac{V_s \times n}{V \times V_a} \quad (\text{公式 2.2})$$

式中： V ：采样体积（L）； V_s ：水样经沉淀浓缩后的体积（mL）； V_a ：计数体积（mL）； n ：每片计数出的浮游动物个数。

2.1.3 数据分析方法

主成分分析（Principal Component Analysis, PCA）又叫主分量分析，是一种通过对多变量进行降维处理的数据线性组合方法，它在尽可能保留原有信息的基础上将高维空间中的样本映射到较低维德主成分空间中。对于变量的主成分分析，可以观察到变量在主成分上的分布，通过各个变量在主成分上的载荷因子大小，找出影响结果的重要变量，从而进一步选择主要表征变量（张尧庭等，1997）。

BP 人工神经网络（Back Propagation Network）是一种单向传播的多层前向网络，每一层节点的输出只影响下一层节点的输出，其网络结构见图 2.2。其中 u 和 y 分别为网络输入、输出向量，每个节点表示一个神经元。网络由输入层、隐层和输出层节点构成，隐层节点可为一层或多层，同层节点没有任何耦合，前层节点到后层节点通过权连接（常晓丽，2006）。输入信号从输入层节点依次传过各隐层节点到达输出层节点。节点的传递函数一般为(0, 1) S 型函数 $f(x) = \frac{1}{1 + e^{-x}}$ ，但在输出层节点的传递函数为线性函数。本文 BP 网络中隐层神经元采用 Matlab7.0 中的 *tansig* 激活函数，输出层神经元采用线性函数 *purelin* 激活函数（JosepH *et al*,2003）。




图 2.2 3 层 BP 人工神经网络结构

Fig. 2.2 3 layers of BP neural network model

隐层节点的输出为：

$$h_{pj} = f_j(\theta_j + \sum_{i=1}^N w_{ji} x_{ui}) \quad (\text{公式 2.3})$$

输出层节点的输出为：

$$y_{pk} = f_k(\theta_k + \sum_{j=1}^L w_{kj} h_{pj}) \quad (\text{公式 2.4})$$

式中 w_{ji} 为 BP 网络结构中输入层 i 节点对隐含层 j 节点的连接权值， w_{kj} 为隐含层 k 节点对输出层 j 节点的连接权值， x_{ui} 为输入层中输入的第 u 个样本的第 i 个特征值， θ_j 和 θ_k 分别为隐层和输出层的阈值， N 为输入样本的个数， L 为隐层节点数， f_j 和 f_k 分别为隐层和输出层的激活函数，即 *tansig* 和 *purelin* 激活函数。

BP 人工神经网络的训练过程由正向和反向传递两部分组成。在网络训练时首先用 Matlab7.0 中的 *newff* 函数初始化网络各层间的连接权值 w_{ji} 、 w_{kj} 和阈值 θ_j 、 θ_k ，使其取得(- 1, 1)之间的随机量，然后输入样本进行学习。在正向传递过程中，每一层神经元的状态只影响下一层神经元网络。如果输出层实际输出与期望输出值之间有误差，那么转入反向传递过程，将误差信号沿原来连接通路返回，通过修改各层神经元的权值，逐次向输入层传递进行计算，再经过正向传递过程，这两个过程反复运用，使误差信号满足实际要求（周继成，1993）。

本文中利用主成分分析用于研究亭下水库 Chl-a 浓度和 WT、pH 值、DO 等几个水体环境变量之间的关系，并通过主成分分析的输出结果选出影响亭下水库水体 Chl-a 浓度动态变化的水体主要环境变量。应用多元统计分析软件

SPSS 对亭下水库叶绿素 a 含量和水体的环境变量进行主成分分析，并输出结果。再利用 BP 人工神经网络方法构建亭下水库叶绿素 a 浓度的预测模型。

2.2 结果

2.2.1 亭下水库主要理化因子

自 2009 年 2 月至 2010 年 1 月对亭下水库进行跟踪监测期间，总共对亭下水库 3 个采样点表层（离水表层 0.5m）水体的 pH、WT、SD 等 7 个环境变量以及表层水体的 Chl-a 含量进行了监测。图 2.3 分别给出了亭下水库 3 个采样点表层水体 pH、WT、DO 等 7 个环境变量随采样时间的监测值（2009.2—2010.1），图 2.3H 给出了亭下水库水体 3 个采样点表层水体叶绿素 a 含量随采样时间的监测值（2009.2—2010.1）。

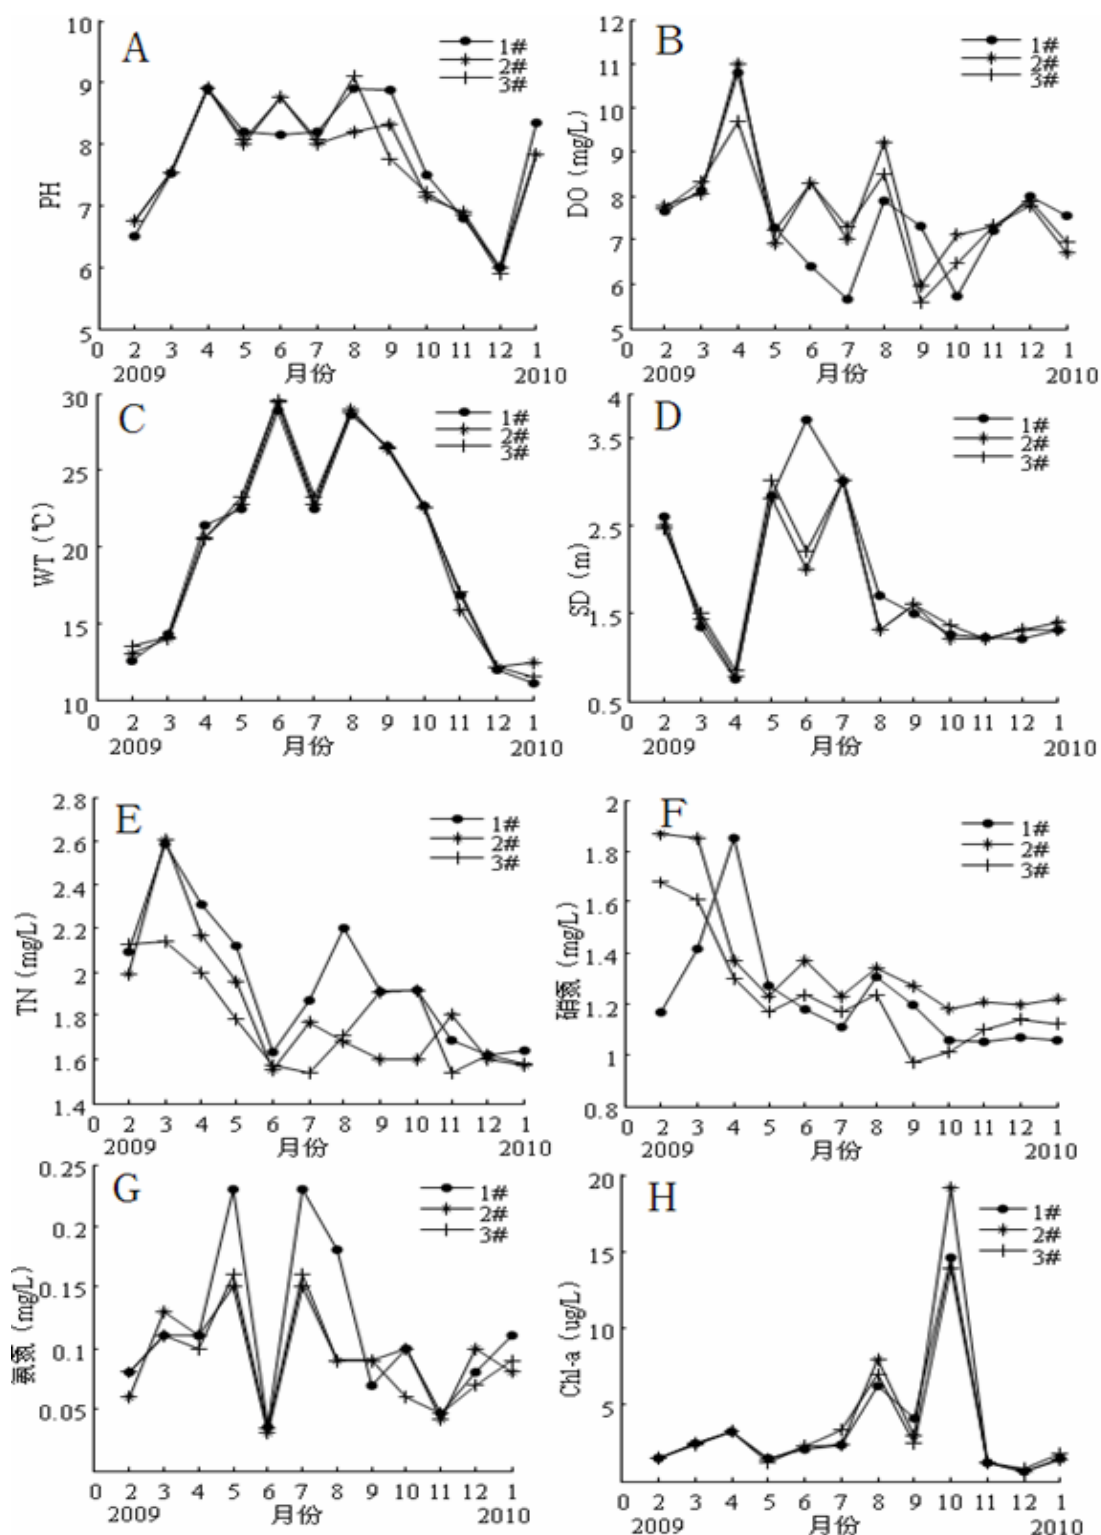


图 2.3 亭下水库各采样点各环境变量随采样时间的监测值

Fig.2.3 The monitoring value of the environmental factors with time in Tingxia Reservoir

从图 2.3 可以看出,在对亭下水库进行跟踪监测期间,2#采样点和 3#采样点的水体 pH、WT、DO 等 7 个环境因子随季节变化趋势基本相同,从地理位置上看,3#采样点位于水库上游,2#采样点位于水库中心位置,两个采样点的地理位置接近,因此,两个采样点的水质状况相似。1#采样点位于水库下游大坝处最能代表整个水库的水质状况,也可以看出 1#采样点和 2#、3#采样点水体各环境因子以及叶绿素 a 含量有所不同,存在一定的差别。

亭下水库库区属亚热带季风气候,在对水库水体进行跟踪监测期间,各采样点水温(图 2.3C)随季节变化明显,最高水温为 29.6℃,出现在 2009 年 6 月份,最低水温为 11.1℃,出现在 2010 年 1 月份。水库水体 PH 变化于 5.90-9.10 之间(图 2.3A),春夏秋三季显著高于冬季。水体溶解氧随季节变化明显(图 2.3B),春季(2009 年 4 月份)螺旋鱼腥藻水华发生期间,水体 DO 最高达 11mg/L,秋季(2009 年 10 月份)微囊藻水华发生期间,水体 DO 呈现出最低 5.73 mg/L,冬季(2009 年 1 月份)则相对较低。水体透明度(图 2.3D)周年波动于 0.75-3.7 之间,2009 年 4 月份因发生螺旋鱼腥藻水华,使得水体的透明度最低 0.75m,到了夏季水华减轻,透明度得以回升,2009 年 10 月份水体因发生微囊藻水华,使得水体的透明度呈现出降低的趋势。水体的总氮、硝氮及氨氮(图 2.3E、图 2.3F、图 2.3G),变化趋势基本相同。水体叶绿素 a 含量(图 2.3H)周年波动于 0.63-19.2 之间,最低出现在 2009 年 12 月份,最高出现在微囊藻水华发生期间(2009 年 10 月份),达到 19.2 ug/L。

2.2.2 浮游藻类

经鉴定,亭下水库共鉴定出浮游植物 75 种,蓝藻 15 种,占总数的 20%;绿藻 39 种,占总数的 52%;硅藻 12 种,占总数的 16%;隐藻 2 种,占总数的 2.7%;裸藻 5 种,占总数的 6.7%;金藻、甲藻各 1 种,占总数的 1.3%。蓝藻和硅藻的种类较多,其中硅藻是藻类数量上的优势类群,绿藻种类最多,但在数量上无明显的优势种群。优势种随季节变化而交替。图 2.4 给出了亭下水库浮游植物各采样点浮游植物数量的周年变化。




图 2.4 亭下水库各采样点浮游植物数量的周年变化

Fig.2.4 Abundance of pHytoplankton at 3 sampling sites in Tingxia Reservoir

从图 2.3 可以看出, 亭下水库各采样点浮游植物丰度出现了两个峰值, 分别是 2009 年 4 月份和 2009 年 10 月份, 浮游植物丰度最大值出现在 2009 年 10 月 2# 采样点, 达 5×10^7 cells/L, 最小值出现在 2009 年 6 月 1# 采样点, 仅为 1.3×10^4 cells/L。整体看来, 亭下水库浮游植物丰度不是很大, 周年处于较低水平。2009 年 4 月因螺旋鱼腥藻大量繁殖, 形成水华使得浮游植物丰度增加, 呈现小的峰值, 2009 年 10 月因微囊藻大量繁殖, 爆发蓝藻水华使得浮游植物丰度剧增, 呈现较大的峰值。

2.2.3 亭下水库叶绿素 a 浓度预测模型构建

BP 人工神经网络作为最常用的人工神经网络结构之一, 已被国内外许多研究人员应用于水生态系统预测模型的构建中, 并取得了良好的结果, 因此, 本文中采用 BP 人工神经网络方法构建亭下水库叶绿素 a 浓度的预测模型。

2.2.3.1 模型的设计、选择及验证

由图 2.1 和水库 3 个采样点的监测数据 (见图 2.3A 到图 2.3G) 可知, 1# 采样点位于水库下游大坝处最能代表整个水库的水质, 2# 采样点 (亭下湖心) 与 3# 采样点 (亭下上游) 的地理位置比较靠近, 两个采样点各环境变量

的数值也基本接近，两个采样点的水体状况大体一致。因此，在构建亭下水库叶绿素 a 浓度的预测模型时，以 1#采样点的监测数据作为 BP 网络的训练数据集，以 2#采样点的监测数据作为 BP 网络的测试数据集。1#采样点和 2#采样点的监测数据见表 2.1、表 2.2。

表 2.1 亭下水库 1#采样点的监测数据

Tab.2.1 The monitoring date of spot 1 in Tingxia Reservoir

月份	2	3	4	5	6	7	8	9	10	11	12	1
PH	6.5	7.53	8.9	8.2	8.16	8.2	8.9	8.88	7.5	6.8	6	8.35
DO/(mg·l ⁻¹)	7.64	8.14	10.8	7.28	6.4	5.65	7.9	7.33	5.73	7.23	8	7.56
WT/°C	12.6	14.3	21.4	22.5	28.9	22.5	28.6	26.6	22.7	16.8	12	11.1
SD/m	2.6	1.34	0.75	2.84	3.7	3	1.7	1.5	1.26	1.22	1.2	1.3
TN/(mg·l ⁻¹)	2.09	2.59	2.31	2.12	1.63	1.87	2.2	1.91	1.92	1.69	1.62	1.64
NO ₃ -N/(mg·l ⁻¹)	1.17	1.42	1.85	1.27	1.18	1.11	1.31	1.2	1.06	1.05	1.07	1.06
NH ₃ -N/(mg·l ⁻¹)	0.08	0.11	0.11	0.23	0.036	0.23	0.18	0.07	0.1	0.047	0.08	0.11
Chl-a/(ug·l ⁻¹)	1.5	2.48	3.24	1.47	2.07	2.39	6.23	4.12	14.6	1.22	0.63	1.49

表 2.2 亭下水库 2#采样点的监测数据

Tab.2.2 The monitoring date of spot 2 in Tingxia Reservoir

月份	2	3	4	5	6	7	8	9	10	11	12	1
PH	6.75	7.54	8.9	8	8.75	8	8.2	8.33	7.13	6.9	6	7.84
DO/(mg·l ⁻¹)	7.8	8.06	11	6.9	8.3	7	9.2	5.98	7.1	7.32	7.78	6.72
WT/°C	13.1	14	20.6	22.8	29.5	22.8	29	26.4	22.6	15.9	12.2	12.5
SD/m	2.5	1.42	0.78	2.8	2	3	1.3	1.6	1.2	1.2	1.3	1.4
TN/(mg·l ⁻¹)	1.99	2.61	2.17	1.96	1.55	1.77	1.68	1.6	1.6	1.8	1.6	1.57
NO ₃ -N/(mg·l ⁻¹)	1.87	1.85	1.37	1.23	1.37	1.23	1.34	1.27	1.18	1.21	1.2	1.22
NH ₃ -N/(mg·l ⁻¹)	0.06	0.13	0.11	0.15	0.031	0.15	0.09	0.09	0.1	0.042	0.1	0.08
Chl-a/(ug·l ⁻¹)	1.48	2.42	3.26	1.36	2.24	2.4	8	2.94	19.2	1.19	0.64	1.43

Peter L.M.Goethals 等（2007）在文章中指出网络模型的输入变量不应是高度相关的，通过主成分分析法可以缩减变量，减少网络噪音，增加网络的训练速度。因此，利用主成分分析法（何亮，2007）分析亭下水库 1#采样点诸因子的地位，对表 2.1 中亭下水库 1#采样点的监测数据利用 SPSS 13.0 软件进行主成分分析，其分析结果见表 2.3。

表 2.3 亭下水库 1#采样点监测数据主成分分析结果

Tab.2.3 The results of Principal component analysis at spot 1 in Tingxia Reservoir

相关系数 (Correlation coefficients)

	PH	DO	WT	SD	TN	NO ₃ -N	NH ₃ -N	Chl-a
PH	1.000							
DO	0.157	1.000						
WT	0.671	-0.223	1.000					
SD	0.061	-0.543	0.374	1.000				
TN	0.269	0.474	0.057	-0.191	1.000			
NO ₃ -N	0.470	0.817	0.185	-0.263	0.717	1.000		
NH ₃ -N	0.375	-0.120	0.199	0.250	0.343	0.127	1.000	
Chl-a	0.183	-0.308	0.387	-0.242	0.130	-0.062	0.028	1.000

各主成分贡献 (Contribution of various principal components)

主成分 Component number	主成分系数 Principal component coefficient								特征值 Eigenvalue	累积贡献率 Cumulative percentage
	PH	DO	WT	SD	TN	NO ₃ -N	NH ₃ -N	Chl-a		
第一 First	0.582	0.777	0.214	-0.376	0.798	0.948	0.269	0.054	2.740	34.25
第二 Second	0.629	-0.547	0.845	0.585	0.016	-0.081	0.520	0.411	2.197	61.71
第三 Third	-0.016	0.097	-0.156	0.590	0.049	0.095	0.392	-0.847	1.265	77.52

由表 2.3 对亭下水库 1#采样点监测数据主成分分析的结果可知, 水体的叶绿素 a 浓度与水体的 DO、WT、SD 和 pH 这 4 个环境变量之间的线性关系较好, 说明在亭下水库中 DO、WT、SD 和 pH 这 4 个环境变量的变化对水体藻类叶绿素 a 的浓度影响较大。通过对亭下水库 1#采样点的监测数据进行的主成分分析, 得到了三个主成分, 从表 2.3 中 1#采样点各环境变量的主成分贡献来看, 第一主成分贡献率是 34.25, 以 NO₃-N、TN 和 DO 这 3 个环境变量的主成分系数较大, 第二主成分贡献率是 27.46, 以 WT 和 pH 这 2 个环境变量的主成分系数较大, 第三主成分贡献率是 15.81, 以 Chl-a 主成分系数较大。

通过表 2.3 中对亭下水库 1#采样点的监测数据各环境变量的主成分分析结果以及对结果的分析可知, 亭下水库中影响水体叶绿素 a 浓度的主要环境变量有 DO、WT、SD、pH、NO₃-N 和 TN 这 6 个因子, 因此, 在应用 BP 神经网络构建亭下水库叶绿素 a 浓度的预测模型时, 以水体的 pH、DO、WT、SD、TN 和 NO₃-N 这 6 个环境变量作为 BP 神经网络的输入变量, 以 Chl-a 浓度作为 BP 网络的输出变量, BP 网络模型的基本结构如图 2.5 所示。




图 2.5 基于 6 个环境变量的监测数据预测叶绿素 a 浓度所采用的神经网络结构

Fig.2.5 The BP neural network model that based on the monitored data of 6 environmental factors to predict the concentration of Chl-a

基于表 2.3 对 1#采样点的监测数据主成分分析结果以及图 2.5，选择 1#采样点中 pH、DO、WT、SD、TN 和 NO₃-N 这 6 个环境变量对应的监测数据作为 BP 网络的训练数据集，选择 2#采样点中相对应的 6 个环境变量对应的监测数据作为 BP 网络的测试数据集。在用训练数据集对 BP 网络训练前先对 1#采样点对应的训练数据集进行标准归一化处理，以统一数据集中各因子的量纲及数量级，加快网络的训练速度。本文采用 Matlab7.0 中的 `prestd`、`poststd` 和 `trastd` 函数对训练数据集进行标准归一化处理，使每组数据都变为均值为 0，方差为 1 的一组数据。函数的具体用法参见文献（罗成汉，2004）。

基于图 2.5 中的神经网络结构和 Matlab7.0 软件，采用 Levenberg-Marquardt 算法对训练数据集进行训练，其在 matlab7.0 中的函数名是 `trainlm`。然后调用 Matlab7.0 中的 `sim` 函数对亭下水库 2#采样点监测数据中对应的测试数据集进行仿真运算输出，以验证训练好的网络和其泛化性能。

在应用 BP 网络构建模型时，隐含层节点数的选择是至关重要的，隐含层节点数不同，BP 网络输出就不同，隐含层节点数的选择直接影响到网络的输出，进而影响到网络的性能。本文采用经验公式（Ma *et al*,2002;Xiong *et al*,2002）来确定 BP 网络隐含层的节点数。

该经验公式如下：

$$J=\sqrt{m+n}+a \quad (\text{公式 2.5})$$

其中 J 表示隐含层节点数, m 表示输入层节点数, n 表示输出层节点数, a 为 1-10 之间的常数。

本文中隐含层节点数有 10 种取值 (具体包括: 4, 5, 6, ..., 13), 因此, 在对构建的 BP 网络进行训练时有 10 种不同的网络结构可选。为了得到 BP 网络训练中的最佳网络, 用亭下水库 2# 采样点监测数据中对应的测试数据集对可选的 10 种不同的网络模型分别进行测试, 通过测试结果中网络模型对叶绿素 a 浓度的预测值与实测值之间的均方误差值 (MSE) 来确定最佳网络 (Zhao *et al*, 2007)。在可选的 10 种不同的网络模型中, 具有最小均方误差值的网络模型被选出来作为预测能力最佳的网络模型。

最佳网络模型通过 BP 网络仿真输出亭下水库叶绿素 a 浓度均方误差值的最小值选出后, 为了进一步分析网络输入的 pH、DO、WT、SD、TN 和 $\text{NO}_3\text{-N}$ 这 6 个环境变量对亭下水库叶绿素 a 浓度的影响大小, 从而确定哪些环境变量对叶绿素 a 浓度起主要作用。本文对选出的最佳网络模型进行了敏感度分析 (Jeong *et al*, 2001; Zar *et al*, 1984)。目前已有许多研究人员使用敏感度分析方法来分析输入变量对输出地影响 (Jeong *et al*, 2001; Goh *et al*, 1995; Lek *et al*, 1996; Siginer, 1997; Dimopoulos *et al*, 1999; 刘建萍等, 2009)。具体做法是: 依次将亭下水库 2# 采样点对应的监测数据中的测试数据集中 6 个环境变量的实测值施以加、减 10% 的干扰, 建立加、减各 10 个敏感度的测试数据组。通过调用 Matlab7.0 中的 sim 函数, 对干扰前后的叶绿素 a 浓度进行两次仿真计算, 并比较两次仿真计算结果的大小。每个环境变量的敏感度按下式计算。

$$\text{Sensitivity}(100\%) = \frac{1}{N} \sum_{i=1}^N \left| \frac{C' - C}{C} \right| \times 100 \quad (\text{公式 2.6})$$

其中 C' 表示对网络输入变量施以干扰值后叶绿素 a 浓度的网络仿真输出值, C 表示对网络输入变量未施干扰值时叶绿素 a 浓度的网络仿真输出值, N 表示网络仿真输出值的个数。

2.2.3.2 BP 网络模型输出结果

在 BP 神经网络的训练过程中, 共有 10 种不同的 BP 神经网络可选, 将这 10 种不同的神经网络在 2# 采样点监测数据中对应的测试数据集上进行评价, 通过验证结果中网络模型对叶绿素 a 浓度的预测值与实测值之间的均方误差值 (MSE) 来确定, 具有最小均方误差值的 BP 神经网络预测能力最好。

表 2.4 列出了 10 种不同的 BP 神经网络模型随隐含层节点数不同叶绿素 a 浓度的预测值与实测值之间的均方误差值。

表 2.4 隐含层不同节点数的均方误差值

Tab.2.4 The MSE of different nodes in the hidden layer

节点	4	5	6	7	8	9	10	11	12	13
均方误差值	26.5	30.1	46.7	30.6	32.9	28.4	36.7	14.8	26.5	18.8

从表 2.4 列出的数据可以看出，当隐含层节点数为 11 时，叶绿素 a 浓度预测值与实测值之间的均方误差之值最小，最小值为 14.8。因此，隐含层节点数为 11 时的 BP 网络为训练获得的最佳 BP 神经网络。利用这个最佳 BP 神经网络来预测亭下水库 2# 采样点所对应的测试数据集中叶绿素 a 的浓度。为了更好的表示 BP 神经网络输出的叶绿素 a 浓度的预测值和实测值，并对两者进行比较，图 2.6 给出了 BP 神经网络输出的叶绿素 a 浓度的预测值和实测值的拟合曲线，图 2.7 给出了 BP 神经网络输出的叶绿素 a 浓度的预测值和实测值的比较。




图 2.6 叶绿素 a 浓度预测曲线（虚线）与实测曲线（实线）的比较

Fig.2.6 Comparison of predicted and observed curve of Chlorophyll-a




图 2.7 叶绿素 a 浓度预测值与实测值的比较

Fig.2.7 Comparison of predicted value and observed value of the concentration of Chlorophyll-a




图 2.8 叶绿素 a 浓度对不同变量施以加、减 10% 干扰的敏感度

Fig.2.8 The sensitivity analysis of the concentration of Chlorophyll-a that carried the interference($\pm 10\%$) on the different variables

2.3 讨论

2.3.1 BP 神经网络预测模型结果分析

如图 2.6 所示，实线代表亭下水库叶绿素 a 浓度的实测值，虚线代表亭下水库叶绿素 a 浓度的预测值，从图 2.6 中可以看出，实线的变化趋势与虚线的变化趋势基本吻合，在 2009 年 2 月份、7 月份和 10 月份，亭下水库叶绿素 a 浓度的预测值与实测值之间有一定的差异，通过分析 1#采样点和 2#采样点的原始监测数据可以看出，1#采样点和 2#采样点的水质状况虽然相似，但由于地理位置相距较远，使得两个采样点之间的水质状况仍存在一定的差异，另外，亭下水库水体的叶绿素 a 浓度除了受水体的 pH、DO、WT、SD 等 7 个环境变量影响外，还受到水体的其他理化以及生物因子的影响，由于在构建 BP 网络模型时，没有把这些理化以及生物因子考虑在内，导致 BP 网络的预测结果与实际结果有所偏差。尽管如此，由图 2.6 可以基本断定，基于 BP 网络构建的预测模型能够较为准确的反映亭下水库叶绿素 a 浓度的变化趋势。

当构建的 BP 神经网络训练结束后，调用 Matlab7.0 中的 sim 函数对模型进行仿真输出，得到 BP 网络模型输出，从而与目标输出进行比较，通过调用 Matlab7.0 中的 postreg 函数对 BP 网络训练结果进行进一步分析，postreg 函数是利用了线性回归的方法来分析网络仿真输出与目标输出的关系。从图 2.7 中可以看出，构建的 BP 神经网络模型输出与目标输出的相关系数 $R=0.768$ ，图 2.7 中，横坐标表示叶绿素 a 浓度的实测值，即目标输出，纵坐标表示叶绿素 a 浓度的预测值，即 BP 网络模型的输出，“○”表示数据，R 值越接近 1 表示网络输出与目标输出越接近，网络性能越好，因此，基于 BP 网络构建的亭下水库叶绿素 a 浓度的预测模型具有较好的泛化性能。

2.3.2 影响亭下水库藻类生长的主要驱动因子

图 2.8 给出了亭下水库叶绿素 a 浓度对不同变量施以加、减 10% 干扰的敏感度。通过敏感度分析，可以找出影响藻类生长的主要驱动因子，由图 2.8 可以看出，水体 SD、TN 和 $\text{NO}_3\text{-N}$ 的变化对亭下水库叶绿素 a 浓度影响不大，DO 的变化对亭下水库叶绿素 a 浓度有一定的影响，但影响不是很显著，WT 的变化对亭下水库叶绿素 a 浓度影响较为显著，pH 和亭下水库叶绿素 a 浓度呈显著相关。

温度是藻类生长的重要限制因素，水温一方面影响藻生命活动的活性、速率，另一方面影响藻对水中营养物的利用率和自身代谢率，敏感度分析结

果表明水温是影响亭下水库水体叶绿素 a 浓度较为敏感的因子，这一研究结果与王得玉等人（2008）对太湖蓝藻爆发与水温关系的研究结果一致。

Yabunaka 等人(1997)通过分析 Kasumigaura 湖 1981 至 1998 年的数据，得出 pH 值与 chl-a 之间具有很强的正相关关系。他们认为，水体中藻生物细胞数的增加导致光合作用的增加，从而使得水体中碳酸离子增加，引起相应的 pH 值增高。Wei 等人(2001)在对 Kasumigaura 湖 1982 年至 1996 年的数据进行分析后也发现 PH 值与 chl-a 之间具有很强的正相关关系。本研究结果表明 pH 值和亭下水库水体叶绿素 a 浓度之间呈显著相关关系， pH 与水体叶绿素 a 浓度之间有很强的正相关关系，因此，本研究的结果与 Yabunaka 和 Wei 等人的研究结果是一致的。

通过敏感度分析结果可知，水体的 pH 值和水温是影响亭下水库藻类生长的主要驱动因子。

2.4 小结

本文以亭下水库周年跟踪监测的水体理化数据为基础，利用主成分分析法分析了影响亭下水库叶绿素 a 浓度的主要环境变量，并以主成分分析选出的这些环境变量为输入变量，基于 BP 人工神经网络和 Matlab7.0 软件，构建了亭下水库叶绿素 a 浓度的预测模型，并对模型输出结果进行了分析。同时，通过调用 Matlab7.0 软件中的 sim 仿真输出函数，对选出的环境变量施以加、减 10%的干扰，对亭下水库水体的叶绿素 a 浓度进行了敏感度分析，由敏感度分析结果可知，水体的 pH 和水温是影响亭下水库藻类生长的主要驱动因子。

3 水库浮游藻类发生动态及预测模型构建—梅湖水库

梅湖水库位于浙江省东北部。水库集雨面积为 23.5km^2 ，主流长度 10km ，总库容 1603万 m^3 ，正常水位 22m ，正常库容为 1284万 m^3 ，正常面积 1.175 km^2 ，是一座集灌溉、防洪、供水、发电的中性饮用水水库。近年来多次爆发规模大、持续时间长的蓝藻水华。为从根本上消除梅湖水库水体富营养化的内源，慈溪市水利局于 2008 年 2 月至 7 月对该水库进行了建库以来的首次清淤，共清淤约 30万 m^3 。并在清淤后采用“表底水体对换”来降低水体表面温度，破坏蓝藻生存环境。

本研究对疏浚后梅湖水库进行了为期一年的跟踪监测，通过对梅湖水库 TN、TP、SD 等各种水体的理化指标以及浮游植物等生物指标的调查，研究其周年变化规律，并利用主成分分析（PCA）等统计方法，探讨影响梅湖水库浮游藻类动态变化的主要水体环境因子。由于调查前一年，梅湖水库实施了包括清淤工程在内的多种治理措施，较大程度上改善了水体环境质量，限制了水体浮游藻类的异常增殖，2009 年 2 月至 2010 年 1 月对水体进行跟踪监测期间，梅湖水库没有发生明显的水华现象。叶绿素 a 是反映水体中浮游植物生物量的综合指标。叶绿素 a 含量的高低与水体中藻类的种类、数量等密切相关，在一定程度上反映水体水质的状况（林佳，2007）。因此叶绿素 a 作为一个重要的考察参数而被应用于水质评价、预测等方面的研究中。本文应用 BP 人工神经网络方法来探究梅湖水库水体叶绿素 a 浓度与水体 TN、TP、SD 等各种水体的理化指标之间的关系，来构建梅湖水库叶绿素 a 浓度的预测模型，以实现梅湖水库藻类的应急监测和预报预警，达到有效预防和应对藻类的目的。

3.1 材料和方法

3.1.1 样品采集

根据梅湖水库的自然地理特征，在对梅湖水库进行跟踪监测时共布设 3 个具有代表性的采样点（图 3.1），其中 1#采样点位于梅湖水库中心最大水深处；2#采样点位于梅湖水库上游段；3#采样点位于梅湖水库饮用水取水口处。于 2009 年 2 月至 2010 年 1 月期间，对水库水体每月跟踪监测 1 次，共采样 12 次。

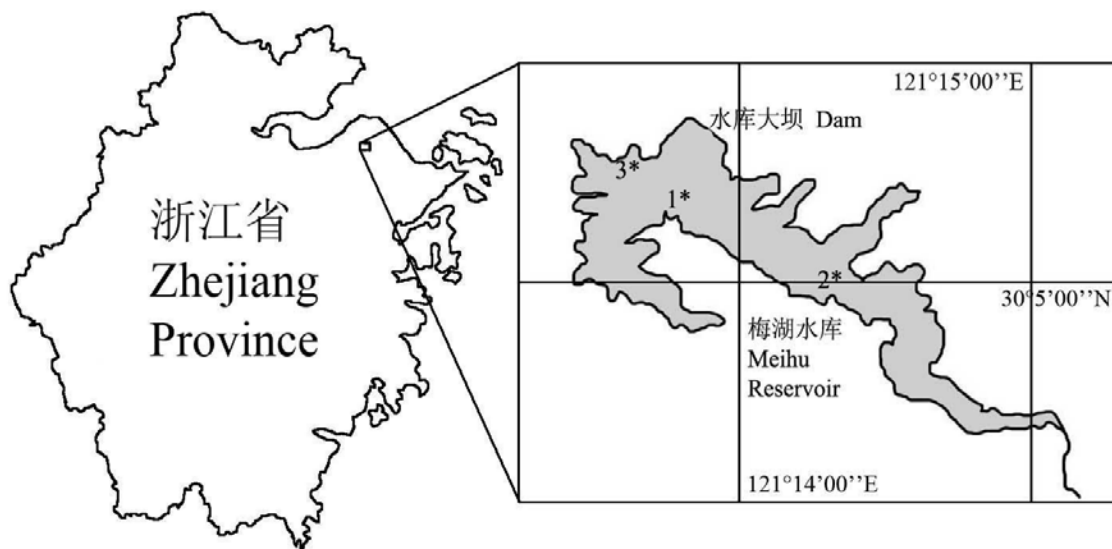


图 3.1 梅湖水库采样点布设图 * 采样点

Fig.3.1 Map of Meihu Reservoir with 3 Sampling sites *Sampling sites

在采样过程中，1#采样点分别采取表（离水表层 0.5m）、中、底（离水底 0.5m）三层水样，2#采样点和 3#采样点只采取表层水样。各采样点均用 5L 采水器采取水样，浮游植物样品取水样 1L，放入定容的塑料瓶中，采得后立即加入 15ml 鲁哥氏液（Lugol's solution）固定（鲁哥氏液配制方法：将 6g 碘化钾溶于 20ml 水中，待其完全溶解后，加入 4g 碘充分摇动，待碘全溶解后加入 80ml 水即可）。浮游动物样品按每个采样点取水样 10L，现场用 25 号浮游生物网过滤，浓缩样品集中于 500ml 的塑料瓶中，并加入 7ml 甲醛固定。用于水化学指标的水样，在各采样点，按各采样点的采集方法采集并单独分析。

3.1.2 水样的测定与分析

见 2.1.2。

3.1.3 数据分析方法

见 2.1.3。

3.2 结果

3.2.1 梅湖水库主要理化因子

自 2009 年 2 月至 2010 年 1 月对梅湖水库进行跟踪监测期间，总共对梅湖水库 3 个采样点表层水体的 pH、WT、SD 等 7 个环境变量以及表层水体的叶绿素 a 含量进行了监测。图 3.2 分别给出了梅湖水库 3 个采样点表层水体

PH、WT、DO 等 7 个环境变量随采样时间的监测值（2009.2—2010.1），图 3.2H 给出了梅湖水库水体 3 个采样点表层水体叶绿素 a 含量随采样时间的监测值（2009.2—2010.1）。

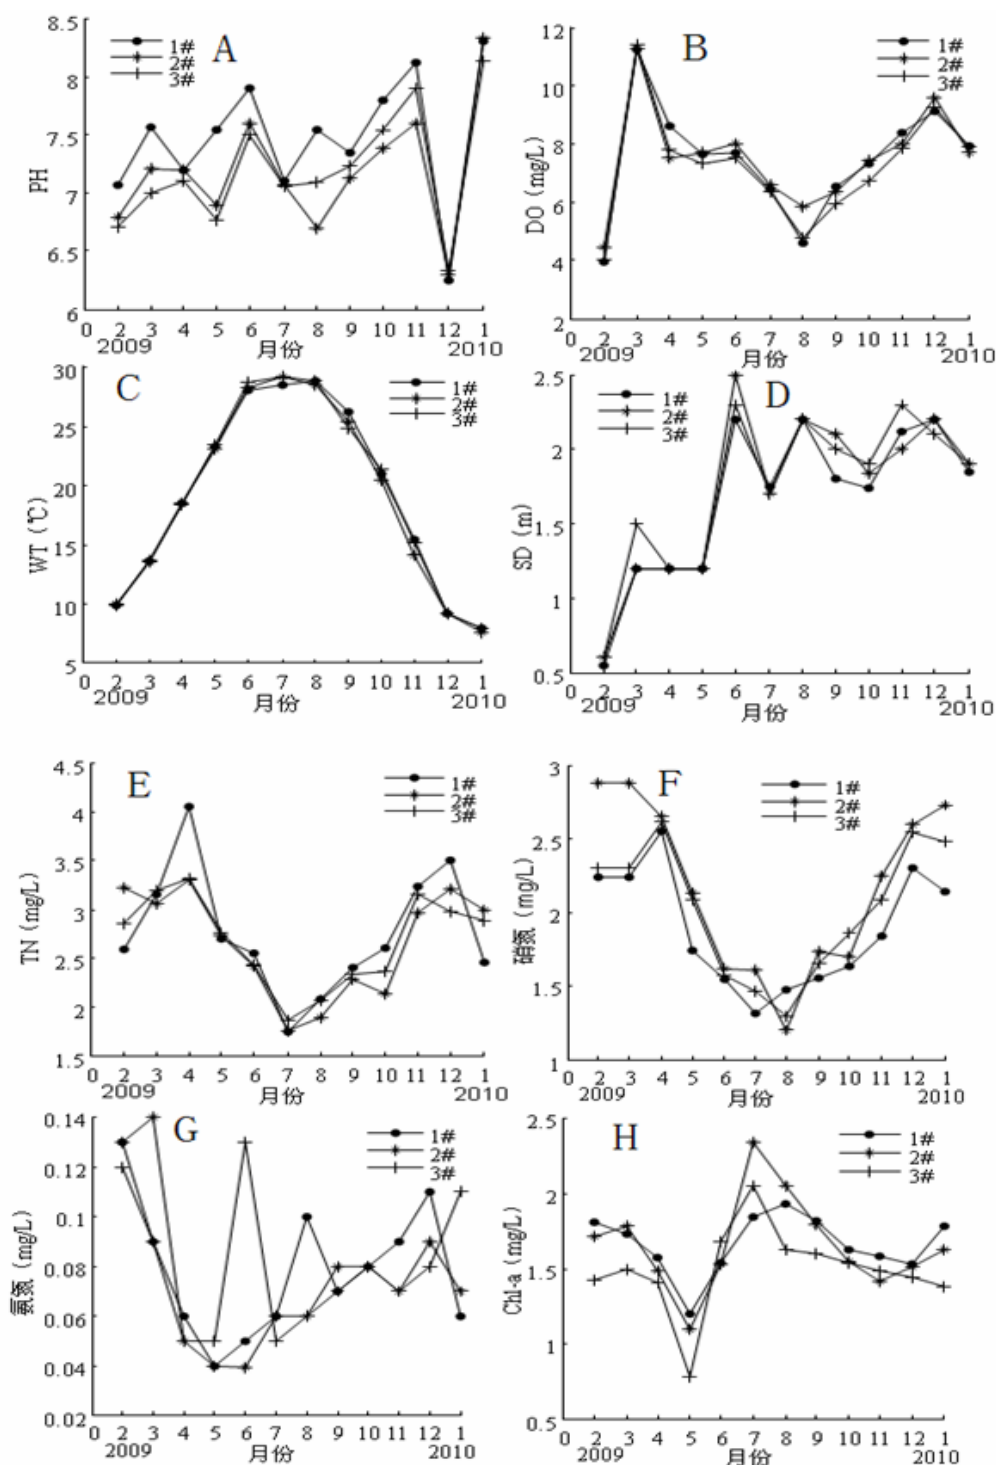


图 3.2 梅湖水库各采样点各环境变量随采样时间的监测值

Fig.3.2 The monitoring value of the environmental factors with time in Meihu Reservoir

梅湖水库库区属亚热带季风气候，图 3.2 分别给出了 pH、DO、WT 等 7 个环境因子随采样时间的变化。从图 3.2 可以看出，在对梅湖水库进行跟踪监测期间，1#采样点和 2#采样点的水体 pH、WT、DO 等 7 个环境因子随季节变化趋势基本相同，从地理位置上看，1#采样点位于梅湖水库库心位置，其水质状况最能代表整个水库的水质，2#采样点位于梅湖水库上游水面开阔处，也能较好的代表部分水体，3#采样点位于梅湖水库取水口的位置，紧靠岸边，其水质状况与 1#采样点和 2#采样点的水质有所差距。

在对梅湖水库进行跟踪监测期间，各采样点 pH（图 3.2A）从监测时间的整体来说随季节波动不是很大，水体最高 pH 为 8.33，出现在 2010 年 1 月，最低 pH 为 6.25，出现在 2009 年 12 月份，这两个月水体 pH 波动较大，可能是受到了上游某些物质的污染。梅湖水库水体 DO 随季节变化明显，DO 变化于 3.94mg/L-11.4mg/L 之间（图 3.2B）。从图 3.2C 可以看出各采样点水温随季节变化明显，最高水温为 29.2℃，出现在 2009 年 7 月份，最低水温为 7.6℃，出现在 2010 年 1 月份。从图 3.2D 可以看出水体 SD 随季节波动较大，最大值为 2.5m，出现在 2009 年 6 月份，最小值为 0.55m，出现在 2009 年 2 月份。从图 3.2E、图 3.2F 和图 3.2G 可知，梅湖水库水体 TN、NO₃-N 及 NH₃-N 随季节变化趋势基本相同。梅湖水库水体叶绿素 a 浓度周年变化于 0.78ug/L-2.34ug/L 之间，最大值出现在 2009 年 7 月份，最小值出现在 2009 年 5 月份。

3.2.2 梅湖水库浮游藻类种类组成

经鉴定，梅湖水库共鉴定出浮游植物 92 种，其中蓝藻 18 种，占 19.56%；绿藻 43 种，占 46.7%；硅藻 23 种，占 25%；裸藻 6 种，占 6.52%；隐藻、金藻和甲藻各一种，各占 1.08%。梅湖水库中蓝藻、绿藻和硅藻三种藻类种类最多，但无明显的优势类群，平均每种藻类都含有一定的数量。图 3.3 给出了梅湖水库浮游植物数量的周年变化。




图 3.3 梅湖水库各采样点浮游植物数量的周年变化

Fig.3.3 Abundance of pHytoplankton at 3 sampling sites in Meihu Reservoir

从图 3.3 可以看出，梅湖水库浮游植物丰度随季节变化比较明显，浮游植物丰度最大值出现在 2010 年 1 月份 1#采样点，达 $8.0 \times 10^6 \text{ cells/L}$ ，最小值出现在 2009 年 7 月份 3#采样点，为 $0.48 \times 10^5 \text{ cells/L}$ 。全年没有发现藻类水华现象。

3.2.3 梅湖水库叶绿素 a 浓度预测模型的构建

基于 BP 人工神经网络方法构建梅湖水库叶绿素 a 浓度的预测模型，方法见 2.2.3。

3.2.3.1 模型的设计、选择及验证

由图 3.1 和梅湖水库 3 个采样点的监测数据（见图 3.2A 到图 3.2G）可知，1#采样点位于梅湖水库库心的位置，最能代表整个水库的水质，2#采样点位于梅湖水库上游且处于水面开阔的水域，1#采样点和 2#采样点的地理位置比较靠近，两个采样点各环境变量的数值也基本接近，两个采样点的水体状况大体一致。因此，在构建梅湖水库叶绿素 a 浓度的预测模型时，以 1#采样点的监测数据作为 BP 网络的训练数据集，以 2#采样点的监测数据作为 BP 网络的测试数据集。1#采样点和 2#采样点的监测数据见表 3.1、表 3.2。

表 3.1 梅湖水库 1#采样点的监测数据

Tab.3.1 The monitoring date of spot 1 in Meihu Reservoir

月份	2	3	4	5	6	7	8	9	10	11	12	1
PH	7.07	7.57	7.2	7.55	7.9	7.1	7.54	7.35	7.8	8.12	6.25	8.31
DO/(mg·l ⁻¹)	3.94	11.22	8.6	7.65	7.7	6.43	4.6	6.54	7.3	8.36	9.12	7.91
WT/°C	9.8	13.6	18.5	23.2	28	28.5	28.8	26.2	21	15.4	9.2	7.9
SD/m	0.55	1.2	1.2	1.2	2.2	1.75	2.2	1.8	1.74	2.12	2.2	1.85
TN/(mg·l ⁻¹)	2.59	3.16	4.05	2.7	2.55	1.75	2.08	2.41	2.6	3.24	3.5	2.46
NO ₃ -N/(mg·l ⁻¹)	2.24	2.24	2.55	1.74	1.55	1.32	1.48	1.56	1.64	1.84	2.3	2.14
NH ₃ -N/(mg·l ⁻¹)	0.13	0.09	0.06	0.04	0.05	0.06	0.1	0.07	0.08	0.09	0.11	0.06
Chl-a/(ug·l ⁻¹)	1.81	1.73	1.57	1.2	1.54	1.84	1.93	1.82	1.63	1.58	1.53	1.78

表 3.2 梅湖水库 2#采样点的监测数据

Tab.3.2 The monitoring date of spot 2 in Meihu Reservoir

月份	2	3	4	5	6	7	8	9	10	11	12	1
PH	6.79	7.21	7.2	6.9	7.6	7.07	6.7	7.13	7.38	7.6	6.3	8.33
DO/(mg·l ⁻¹)	4.45	11.23	7.5	7.7	8	6.59	5.85	6.34	7.4	8	9.6	7.69
WT/°C	9.9	13.5	18.5	23	28.2	29.1	28.5	25.4	20.4	14	9.1	7.6
SD/m	0.6	1.2	1.2	1.2	2.5	1.7	2.2	2.1	1.84	2	2.2	1.9
TN/(mg·l ⁻¹)	3.22	3.06	3.3	2.72	2.42	1.76	1.89	2.28	2.13	2.96	3.21	3
NO ₃ -N/(mg·l ⁻¹)	2.88	2.88	2.65	2.13	1.62	1.61	1.2	1.73	1.7	2.25	2.6	2.73
NH ₃ -N/(mg·l ⁻¹)	0.13	0.14	0.05	0.04	0.039	0.06	0.06	0.08	0.08	0.07	0.09	0.07
Chl-a/(ug·l ⁻¹)	1.71	1.78	1.49	1.1	1.53	2.34	2.05	1.79	1.55	1.42	1.51	1.63

基于 BP 人工神经网络构建梅湖水库叶绿素 a 浓度的预测模型时，在预测模型中输入变量不同，模型的输出结果不同，有些环境变量产生的网络“噪音”会影响到预测模型的输出，因此，Peter L.M.Goethals 等（2007）在文章中指出网络模型的输入变量不应是高度相关的，通过主成分分析法可以缩减变量，减少网络“噪音”，增加网络的训练速度。为了使预测模型的输出结果更准确，利用主成分分析法（何亮，2007）分析梅湖水库 1#采样点监测项目中各环境变量的地位，对表 3.1 中梅湖水库 1#采样点的监测数据利用 SPSS 13.0 软件进行主成分分析，其分析结果见表 3.3。

表 3.3 梅湖水库 1#采样点监测数据主成分分析结果

Tab.3.3 The results of Principal component analysis at spot 1 in Meihu Reservoir

相关系数 (Correlation coefficients)

	PH	DO	WT	SD	TN	NO ₃ -N	NH ₃ -N	Chl-a
PH	1.000							
DO	0.066	1.000						
WT	0.099	-0.323	1.000					
SD	0.168	0.117	0.309	1.000				
TN	-0.226	0.617	-0.512	-0.173	1.000			

NO ₃ -N	-0.262	0.422	-0.817	-0.466	0.810	1.000		
NH ₃ -N	-0.414	-0.270	-0.482	-0.156	0.116	0.322	1.000	
Chl-a	0.011	-0.428	0.055	0.076	-0.471	-0.175	0.435	1.000

各主成分贡献 (Contribution of various principal components)

主成分 Component number	主成分系数 Principal component coefficient								特征值 Eigenvalue	累积贡献率 Cumulative percentage
	PH	DO	WT	SD	TN	NO ₃ -N	NH ₃ -N	Chl-a		
第一 First	-0.325	0.556	-0.811	-0.424	0.874	0.954	0.324	-0.351	3.152	39.40
第二 Second	0.422	0.634	0.243	0.302	0.269	-0.108	-0.827	-0.703	1.992	64.30

基于 SPSS13.0 统计分析软件对梅湖水库 1#采样点监测数据主成分分析结果, 得到了两个主成分, 由表 3.3 中主成分分析结果中各环境变量的相关系数可知, 梅湖水库水体的叶绿素 a 浓度与水体的 TN、NH₃-N 和 DO 这 3 个环境变量之间的线性关系较好, 说明在梅湖水库 TN、NH₃-N 和 DO 这 3 个环境变量的变化对水体藻类叶绿素 a 的浓度影响较大。由表 3.3 主成分分析结果中各环境变量的贡献率可知, 第一主成分贡献率是 39.40, 以 NO₃-N、TN 和 WT 这 3 个环境变量的主成分系数较大, 第二主成分贡献率是 24.9, 以 NH₃-N、DO 和 Chl-a 这 3 个环境变量的主成分系数较大。

通过表 3.3 中对梅湖水库 1#采样点的监测数据各环境变量的主成分分析结果以及对结果的分析可知, 梅湖水库中影响水体叶绿素 a 浓度的主要环境变量有 NO₃-N、TN、WT、NH₃-N 和 DO 这 5 个因子, 因此, 在应用 BP 神经网络构建梅湖水库叶绿素 a 浓度的预测模型时, 以水体的 DO、WT、TN、NO₃-N 和 NH₃-N 这 5 个环境变量作为 BP 神经网络的输入变量, 以 Chl-a 浓度作为 BP 网络的输出变量, BP 网络模型的基本结构如图 3.4 所示。




图 3.4 基于 5 个环境变量的监测数据预测叶绿素 a 浓度所采用的神经网络结构

Fig.3.4 The BP neural network model that based on the monitored data of 5 environmental factors to predict the concentration of Chl-a

在构建梅湖水库叶绿素 a 浓度的 BP 网络预测模型时, 选择用 1#采样点的监测数据作为 BP 网络的训练数据集, 通过对 1#采样点的监测数据进行主成分分析, 从 1#采样点 7 个环境变量中选出 DO、WT、TN 等 5 个环境变量作为 BP 网络的输入变量, 因此, 基于表 3.3 对 1#采样点的监测数据主成分分析结果以及图 3.4 展示的 BP 神经网络结构, 选择 1#采样点中 DO、WT、TN、NO₃-N 和 NH₃-N 这 5 个环境变量对应的监测数据作为 BP 网络的训练数据集, 选择 2#采样点中相对应的 5 个环境变量对应的监测数据作为 BP 网络的测试数据集。在用训练数据集对 BP 网络训练前先对 1#采样点对应的训练数据集进行标准归一化处理, 以统一数据集中各因子的量纲及数量级, 加快网络的训练速度。本文采用 Matlab7.0 中的 `prestd`、`poststd` 和 `trastd` 函数对训练数据集进行标准归一化处理, 使每组数据都变为均值为 0, 方差为 1 的一组数据。函数的具体用法参见文献(罗成汉, 2004)。

基于图 3.4 中的神经网络结构和 Matlab7.0 软件, 采用 Levenberg-Marquardt 算法对训练数据集进行训练, 其在 matlab7.0 中的函数名是 `trainlm`。然后调用 Matlab7.0 中的 `sim` 函数对梅湖水库 2#采样点监测数据中对应的测试数据集进行仿真运算输出, 以验证训练好的网络和其泛化性能。

梅湖水库叶绿素 a 浓度预测模型构建过程中, BP 模型最佳网络的选择、隐含层节点数的选择以及取值等方法同亨下水库叶绿素 a 浓度预测模型的构建相同。见 2.2.3.1。

最佳网络模型通过 BP 网络仿真输出梅湖水库叶绿素 a 浓度均方误差值的最小值选出后, 为了进一步分析网络输入的 DO、WT、TN、NO₃-N 和 NH₃-N 这 5 个环境变量对梅湖水库叶绿素 a 浓度的影响大小, 从而确定哪些环境变量对叶绿素 a 浓度起主要作用。本文对选出的最佳网络模型进行了敏感度分析(Jeong *et al*,2001;Zar *et al*,1984)。目前已有许多研究人员使用敏感度分析方法来分析输入变量对输出地影响(Jeong *et al*,2001;Goh *et al*,1995;Lek *et al*,1996;Siginer,1997;Dimopoulos *et al*,1999;刘建萍等, 2009)。具体做法是: 依次将梅湖水库 2#采样点对应的监测数据中的测试数据集中 5 个环境变量的实测值施以加、减 10%的干扰, 建立加、减各 10 个敏感度的测试数据组。通过调用 Matlab7.0 中的 `sim` 函数, 对干扰前后的叶绿素 a 浓度进行两次仿真计算, 并比较两次仿真计算结果的大小。每个环境变量的敏感度按下式计算。

$$\text{Sensitivity}(100\%) = \frac{1}{N} \sum_{i=1}^N \left| \frac{C'_i - C_i}{C_i} \right| \times 100 \quad (\text{公式 3.2})$$

其中 C'_i 表示对网络输入变量施以干扰值后叶绿素 a 浓度的网络仿真输出值， C_i 表示对网络输入变量未施干扰值时叶绿素 a 浓度的网络仿真输出值， N 表示网络仿真输出值的个数。

3.2.3.2 BP 网络模型输出结果

在 BP 神经网络的训练过程中，共有 10 种不同的 BP 神经网络可选，将这 10 种不同的神经网络在 2# 采样点监测数据中对应的测试数据集上进行评价，通过验证结果中网络模型对叶绿素 a 浓度的预测值与实测值之间的均方误差值（MSE）来确定，具有最小均方误差值的 BP 神经网络预测能力最好。表 3.4 列出了 10 种不同的 BP 神经网络模型随隐含层节点数不同叶绿素 a 浓度的预测值与实测值之间的均方误差值。

表 3.4 隐含层不同节点数的均方误差值

Tab.3.4 The MSE of different nodes in the hidden layer

节点	4	5	6	7	8	9	10	11	12	13
均方误差值	0.08	0.069	0.053	0.032	0.059	0.026	0.048	0.033	0.049	0.041

从表 3.4 列出的数据可以看出，当隐含层节点数为 9 时，叶绿素 a 浓度预测值与实测值之间的均方误差之值最小，最小值为 0.026。因此，隐含层节点数为 9 时的 BP 网络为训练获得的最佳 BP 神经网络。利用这个最佳 BP 神经网络来预测梅湖水库 2# 采样点所对应的测试数据集中叶绿素 a 的浓度。为了更好的表示 BP 神经网络输出的叶绿素 a 浓度的预测值和实测值，并对两者进行比较，图 3.5 给出了 BP 神经网络输出的叶绿素 a 浓度的预测值和实测值的拟合曲线，图 3.6 给出了 BP 神经网络输出的叶绿素 a 浓度的预测值和实测值的比较。




图 3.5 叶绿素 a 浓度预测曲线（虚线）与实测曲线（实线）的比较

Fig.3.5 Comparison of predicted and observed curve of Chlorophyll-a




图 3.6 叶绿素 a 浓度预测值与实测值的比较

Fig.3.6 Comparison of predicted value and observed value of the concentration of Chlorophyll-a




图 3.7 叶绿素 a 浓度对不同变量施以加、减 10% 干扰的敏感度

Fig.3.7 The sensitivity analysis of the concentration of Chlorophyll-a that carried the interference($\pm 10\%$) on the different variables

3.3 讨论

3.3.1 BP 神经网络预测模型结果分析

如图 3.5 所示，实线代表梅湖水库叶绿素 a 浓度的实测值，虚线代表梅湖水库叶绿素 a 浓度的预测值，从图 3.5 中可以看出，实线的变化趋势与虚线的变化趋势基本吻合，在 2009 年 7 月这个峰值，梅湖水库叶绿素 a 浓度的预测值与实测值之间有一定的差异，可能是受到了梅湖水库中其他一些理化及生物因子的影响，因为梅湖水库水体的叶绿素 a 浓度除了受水体的 pH、DO、WT、SD 等 7 个环境变量影响外，还受到水体的其他理化以及生物因子的影响，由于在构建 BP 网络模型时，没有把这些理化以及生物因子考虑在内，导致 BP 网络的预测结果与实际结果有所偏差。尽管如此，由图 3.5 可以基本断定，基于 BP 网络构建的预测模型能够较为准确的反映梅湖水库叶绿素 a 浓度的变化趋势。

当构建的 BP 神经网络训练结束后，调用 Matlab7.0 中的 sim 函数对模型进行仿真输出，得到 BP 网络模型输出，从而与目标输出进行比较，通过调用 Matlab7.0 中的 postreg 函数对 BP 网络训练结果进行进一步分析，postreg 函数是利用了线性回归的方法来分析网络仿真输出与目标输出的关系。从图 3.6 中可以看出，构建的 BP 神经网络模型输出与目标输出的相关系数 $R=0.877$ ，图 3.6 中，横纵坐标的标注形式同图 2.7 相同。图 3.5 中的实线代表最佳回归直线，虚线代表网络输出的叶绿素 a 浓度的预测值等于实测值的理想回归直

线，由此可知，基于 BP 网络构建的梅湖水库叶绿素 a 浓度的预测模型具有较好的泛化性能。

3.3.2 影响亭下水库藻类生长的主要驱动因子

图 3.7 给出了梅湖水库叶绿素 a 浓度对不同变量施以加、减 10% 干扰的敏感度。通过敏感度分析，可以找出影响梅湖水库藻类生长的主要驱动因子，由图 3.7 可以看出，水体中氨氮的变化对梅湖水库叶绿素 a 浓度影响很小，溶解氧和总氮的变化对梅湖水库叶绿素 a 浓度有一定的影响，但影响不是很显著，水体的温度和硝氮的变化对梅湖水库叶绿素 a 浓度影响较为显著。

温度是藻类生长的重要限制因素，水温一方面影响藻生命活动的活性、速率，另一方面影响藻对水中营养物的利用率和自身代谢率，敏感度分析结果表明水温是影响梅湖水库水体叶绿素 a 浓度较为敏感的因子，这一研究结果与王得玉等人（2008）对太湖蓝藻爆发与水温关系的研究结果一致。

硝氮作为藻类生长必须的营养因子，影响着藻类生命活动的活性及生长速率。图 3.7 敏感度分析结果可以看出，硝氮是影响梅湖水库水体叶绿素 a 浓度较为敏感的因子，这可能是由于梅湖水库经过清淤疏浚处理后，在很大程度上消除了水体的氮源，使得水体中氮元素的含量降低，氮元素的缺失最终使得硝氮成为影响水体藻类生长的敏感因子。

通过图 3.7 以及对敏感度分析的结果可知，水体的水温和硝氮是影响梅湖水库藻类生长的主要驱动因子。

3.4 小结

本文以梅湖水库周年跟踪监测的水体理化数据为基础，利用主成分分析法分析了影响梅湖水库叶绿素 a 浓度的主要环境变量，从 pH、WT、SD、DO、TN、NO₃-N 和 NH₃-N 这 7 个环境变量中选出 DO、WT、TN、NO₃-N 和 NH₃-N 这 5 个环境变量作为输入变量，基于 BP 人工神经网络和 Matlab7.0 软件，构建了梅湖水库叶绿素 a 浓度的预测模型，并对模型输出结果进行了分析。同时，通过调用 Matlab7.0 软件中的 sim 仿真输出函数，对选出的环境变量施以加、减 10% 的干扰，对梅湖水库水体的叶绿素 a 浓度进行了敏感度分析，由敏感度分析结果可知，水体的水温和硝氮是影响梅湖水库藻类生长的主要驱动因子。

4 藻华浮游藻类发生动态及预测模型构建—校内池塘

采样池塘位于宁波大学内部，是2个小型藻华水体，水体富营养化程度严重，多年发生蓝藻水华。由于这两个池塘所处地理位置和周遭环境差不多，水质情况相似，现只选择其中的一个池塘展开深入的研究。

4.1 研究对象和方法

4.1.1 采样池塘概况

选择的池塘水体富营养化严重，多年发生蓝藻水华，优势藻类主要为蓝藻门的微囊藻属（*Microcystis* sp.）、色球藻属（*Chroococcus* sp.）和颤藻属（*Oscillatoria* sp.）等的一些常见种类。水华常于春夏之交开始出现，持续至深秋甚至初冬。在2009年3月至2009年10月对水体进行调查期间，暴发了颤藻水华，并持续数月。

4.1.2 BP 人工神经网络方法

见2.1.3。

4.2 数据采集

自2009年3月至2009年10月，在宁波大学校内池塘小型藻华水体的采样地点每周进行一次水体采样，采样过程中只采取表层（离水表层0.5m）水体，共计30周。监测因子中环境变量具体包括总氮（TN，mg/L）、总磷（TP，mg/L）、透明度（SD，m）、溶解氧（DO，mg/L）、pH、温度（WT，℃）。此外，在采样点用5L采水器采取水样，然后取水样1L作为浮游植物样品，放入定容的塑料瓶中，采得后立即加入15ml鲁哥氏液（Lugol's solution）固定（鲁哥氏液配制方法：将6g碘化钾溶于20ml水中，待其完全溶解后，加入4g碘充分摇动，待碘全溶解后加入80ml水即可）。其中SD、DO、pH和WT用仪器在现场测定，TN、TP在实验室中分别用碱性过硫酸钾消解紫外分光光度法和钼锑抗分光光度法测定（金相灿等，1990），浮游植物的鉴定参见文献（章宗涉等，1991；韩茂森等，1995）。数据计算依据文献（金相灿等，1990），然后从浮游植物数据中整理出颤藻（*Oscillatoria*）生物量的数据。图4.1分别给出了总氮、总磷等6个环境变量随采样时间的监测值（2009.3—2009.10），图4.1G给出了颤藻（*Oscillatoria*）生物量随采样时间的检测值（2009.3—2009.10）。

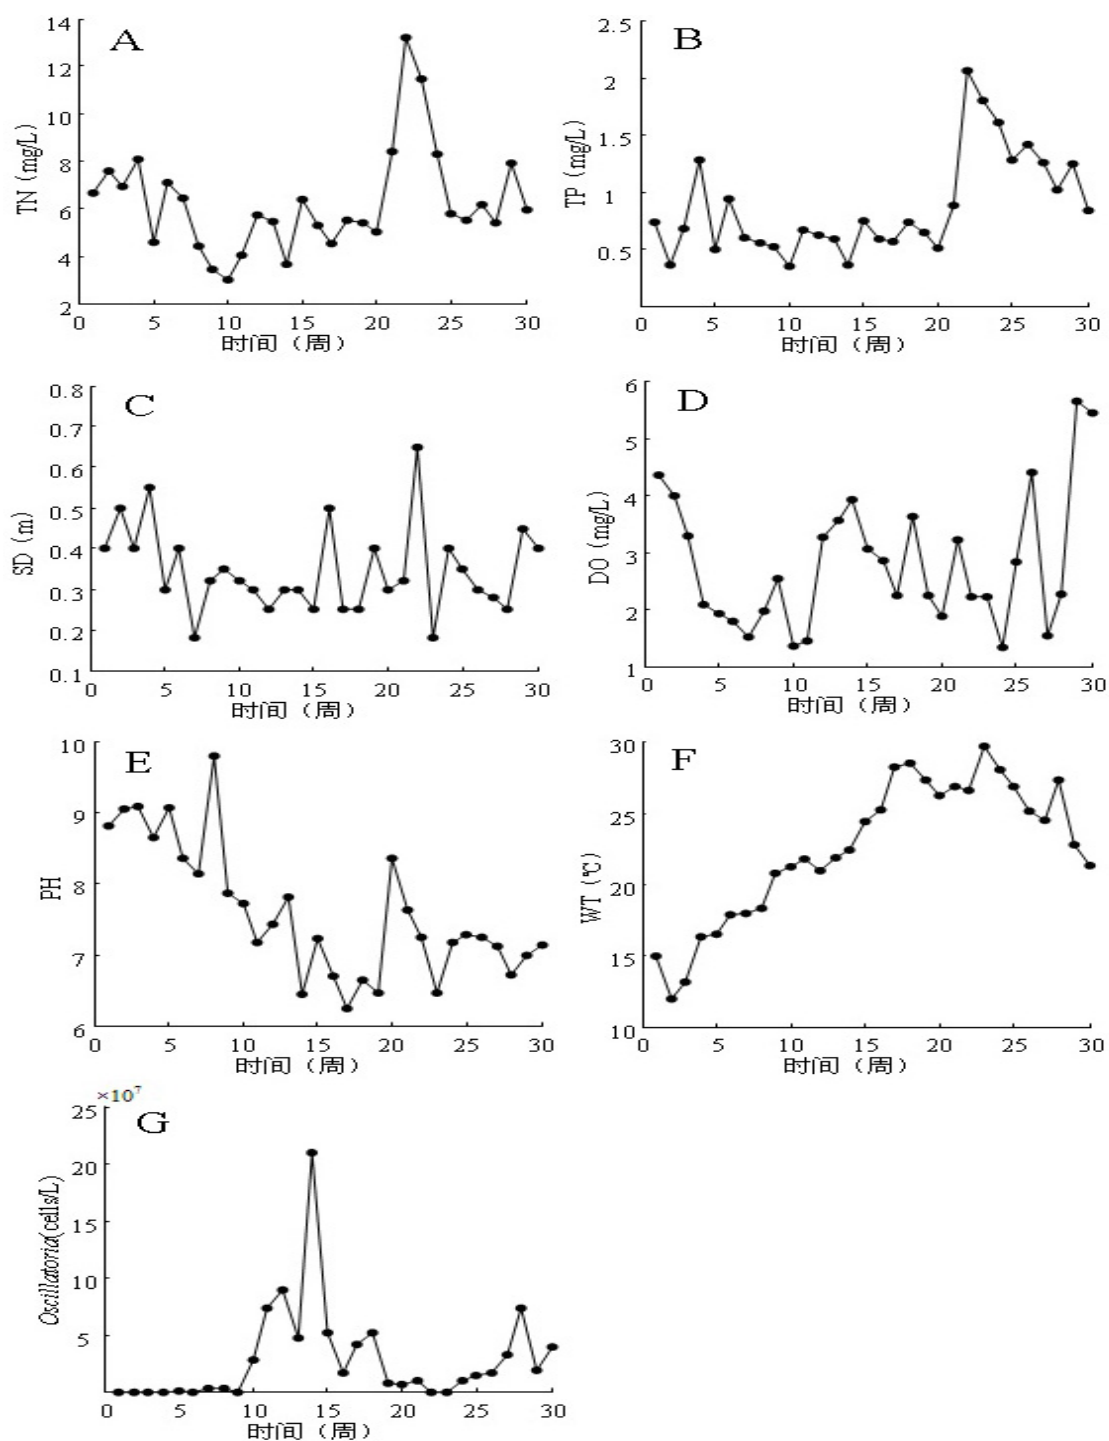


图 4.1 池塘各环境变量及颤藻 (*Oscillatoria*) 生物量随采样时间的监测值

Fig.4.1 The monitoring value of the environmental factors and the density of *Oscillatoria* with time in the pond

此外，表 4.1 给出了这些监测值的相关统计量。

表 4.1 校内池塘采样数据的相关统计量

Tab4.1 The related statistics of monitored data in the school pond

环境变量	最小值	最大值	平均值	标准差
SD(m)	0.18	0.65	0.35	0.11
TN(mg/L)	3.03	13.2	6.25	2.19
TP(mg/L)	0.35	2.06	0.86	0.44
pH	6.24	9.79	7.60	0.93
WT(°C)	12	29.7	22.5	4.86
DO(mg/L)	1.32	5.64	2.80	1.17
<i>Oscillatoria</i> (cells/L)	0	21×10^7	2.81×10^7	4.28×10^7

4.3 采样池塘浮游植物种类组成及其丰度变化

经初步鉴定，该次监测采样池塘中共出现浮游植物28种，蓝藻8种，占总数的28.57%；绿藻16种，占总数的57.14%；硅藻1种，占总数的3.57%；隐藻1种，占总数的3.57%；裸藻2种，占总数的7.14%（表4.2）。因此，在采样池塘浮游植物群落中蓝藻群落和绿藻群落是优势藻类，两者的细胞浓度随采样时间的变化见图4.2、图4.3。

表 4.2 采样池塘浮游藻类种类组成

Tab 4.2 Species list of planktonic algae found of the pond

种名	Species	种名	Species
席藻	<i>PHormidium</i>	集星藻	<i>Actinastrum</i>
颤藻	<i>Oscillatoria</i>	微芒藻	<i>Micractinium</i>
平裂藻	<i>Merismopedia</i>	小椿藻	<i>Characium</i>
微囊藻	<i>Microcystis</i>	韦氏藻	<i>Westella</i>
螺旋藻	<i>Spirulina</i>	弓形藻	<i>Schroederia</i>
色球藻	<i>Chroococcua</i>	空星藻	<i>Coelastrum</i>
蓝纤维藻	<i>Dactylococcopsis</i>	十字藻	<i>Crucigenia</i>
项圈藻	<i>Anabaenopsis</i>	鼓藻	<i>Cosmarium</i>
衣藻	<i>Chlamydomonas</i>	翼膜藻	<i>Pteromonas</i>
四尾栅藻	<i>Scenedesmus</i>	齿牙栅藻	<i>Scenedesmus denticulatus</i> Lag
纤维藻	<i>Ankistrodismus</i>	颗粒直链藻	<i>Melosira granulata</i>
空球藻	<i>Eudorina</i>	隐藻	<i>Cryptomonas</i>
四角藻	<i>Tetraedrom</i>	裸藻	<i>Euglena</i>
蹄形藻	<i>Kirchneriella</i>	磷孔藻	<i>Lepocinclis</i>




图 4.2 采样池塘蓝藻细胞浓度随采样时间的变化

Fig. 4.2 The changes of the density of cyanobacteria of the sampling pond with the sampling time




图 4.3 采样池塘绿藻细胞浓度随采样时间的变化

Fig.4.3 The changes of the density of green algae of the sampling pond with the sampling time

由图 4.2、图 4.3 可以看出，在对采样池塘进行跟踪监测的 30 周的时间里，蓝藻细胞的平均浓度大于绿藻细胞的平均浓度。通过对图 4.2、图 4.3 的对比可知，在采样前期阶段绿藻细胞的平均浓度大于蓝藻细胞的平均浓度，

绿藻群落大量繁盛，可称为绿藻期，随着采样时间的推进，绿藻细胞的平均浓度和蓝藻细胞的平均浓度均呈现出逐渐增大的趋势，绿藻群落和蓝藻群落并存且大量繁盛，可称为蓝绿藻期，在采样的后期阶段，绿藻细胞的平均浓度逐渐减小，蓝藻细胞的平均浓度大于绿藻细胞的平均浓度，蓝藻群落大量繁盛，可称为蓝藻期。

综合图 4.2、图 4.3 的对比结果以及采样的具体时间和季节可知，在对采样池塘进行为期 30 周的跟踪监测过程中，采样池塘浮游植物丰度繁盛期过程可分为绿藻期、蓝绿藻期、蓝藻期三个阶段，其中绿藻在春季大量繁盛形成高峰期，绿藻和蓝藻在春末夏初大量繁盛共同形成高峰期，蓝藻在夏季大量繁盛形成高峰期，并延续至秋季。

4.4 模型的设计、选择及验证

4.4.1 模型数据集的选取及处理

在对宁波大学校内池塘小型藻华水体进行跟踪调查期间，共有 30 周的监测数据。在模型构建过程中，选择 TN、TP、SD、DO、pH、WT 这 6 个环境变量作为网络的输入变量，因为在对池塘进行跟踪监测期间出现了颤藻（*Oscillatoria*）水华，所以选择颤藻（*Oscillatoria*）生物量作为网络的输出变量。

为了提高模型构建过程中神经网络的预测性能，选取滞后 2 个周的环境变量历史数据作为网络的输入，考虑到颤藻是在监测过程中第 5 周开始出现的，最终选择从第 3 周开始共计 28 周的监测数据作为模型构建的原数据。由于模型构建中以滞后 2 个周的环境变量作为输入，以第 3 个周的颤藻生物量作为输出，因此，28 周的监测原数据中共有 26 个数据集，这 26 个数据集构成了本文模型构建的整个数据集。

过度拟合（overfitting）是神经网络训练中经常出现的一个问题（Tzafestas et al,1996）。本文中为了解决神经网络过度拟合，改善神经网络概括归纳能力，采用交叉检验法（Cross-validation）（Amari et al,1997;Rivals et al,1999）对整个数据集进行处理，将整个数据集分为三部分：训练数据集、校验数据集和测试数据集。26 个数据集中选择 18 个作为训练数据集，随机选择 4 个作为校验数据集，随机选择 4 个作为测试数据集。在模型构建中，最终确定第 8、14、18、23 周对应的数据集作为校验数据集，第 10、15、27、30 周对应的数据集作为测试数据集，剩余 18 周对应的数据集作为训练数据集。

4.4.2 模型的构建及选择

4.4.2.1 模型的构建

在构建模型时，以滞后 2 个周的环境变量作为输入，以第 3 个周的颤藻生物量作为输出。换句话说，最终选定的 BP 神经网络输入包含 TN、TP、SD、DO、pH、WT 这 6 个环境变量第 (n-1) 个周和第 (n-2) 个周的监测数据（如图 4.4 所示），因此，BP 神经网络输入层的 12 个神经元分别对应 6 个环境变量滞后 2 个周的监测数据，而网络的输出是第 n 个周的颤藻（*Oscillatoria*）生物量。




图4.4基于滞后两个周的监测数据预测第n个周颤藻（*Oscillatoria*）生物量所采用的神经网络结构

Fig.4.4 The BP neural network model that based on the monitored data of two weeks later to predict the density of *Oscillatoria* of the n week

4.4.2.2 BP 网络的训练、验证及最佳网络的选择

在网络训练前先对 18 周的训练数据集进行标准归一化处理，以统一数据集中各因子的量纲及数量级，加快网络的训练速度。本文采用 Matlab7.0 中的 prestd、poststd 和 trastd 函数对训练数据集进行标准归一化处理，使每组数据都变为均值为 0，方差为 1 的一组数据。函数的具体用法参见文献（罗成汉，2004）。

基于图 4.4 中的神经网络结构和 Matlab7.0 软件，采用 Levenberg-Marquardt 算法对训练数据集进行训练，其在 matlab7.0 中的函数名是 trainlm。然后调用 Matlab7.0 中的 sim 函数对数据集中的校验数据集和测试数据集分别进行仿真运算输出，以验证训练好的网络和其泛化性能。

基于 BP 人工神经网络方法构建池塘颤藻生物量的预测模型时, BP 模型最佳网络的选择、隐含层节点数的选择以及取值等方法同亨下水库叶绿素 a 浓度预测模型的构建相同。见 2.2.3.1。

4.4.3 模型的敏感度分析

最佳网络模型选出后, 为了进一步分析网络输入的各个环境变量对颤藻生物量的影响大小, 从而确定哪些环境变量对颤藻生长、水华发生发展起主要作用。本文对选出的网络模型进行了敏感度分析 (Jeong *et al*,2001;Zar *et al*,1984)。目前已有许多研究人员使用敏感度分析方法来分析输入变量对输出地影响 (Jeong *et al*,2001;Goh *et al*,1995;Lek *et al*,1996;Siginer,1997;Dimopoulos *et al*,1999;刘建萍等, 2009)。具体做法是: 依次将测试数据集中 6 个环境变量的 2 个分量的实测值施以加、减 10% 的干扰, 建立加、减各 10 个敏感度的测试数据组。通过调用 Matlab7.0 中的 sim 函数, 对干扰前后的颤藻生物量进行两次仿真计算, 并比较两次仿真计算结果的大小。每个环境变量的敏感度下式计算。

$$\text{Sensitivity}(100\%) = \frac{1}{N} \sum_{i=1}^N \left| \frac{C' - C}{C} \right| \times 100 \quad (\text{公式 4.2})$$

其中 C' 表示对网络输入变量施以干扰值后颤藻生物量的网络仿真输出值, C 表示对网络输入变量未施干扰值时颤藻生物量的网络仿真输出值, N 表示网络仿真输出值的个数。

4.5 结果与讨论

4.5.1 训练获得的神经网络及其验证

在 BP 神经网络的训练过程中, 共有 11 种不同的神经网络可选, 将这 11 种不同的神经网络在校验数据集上进行评价, 通过校验结果中网络模型对颤藻生物量的预测值与实测值之间的均方误差值 (MSE) 来确定, 具有最小均方误差值的 BP 神经网络预测能力最好。表 4.3 列出了 11 种不同的神经网络随隐含层节点数不同颤藻生物量的预测值与实测值之间的均方误差值。

表 4.3 隐含层不同节点数的均方误差值

Tab2 The MSE of different nodes in the hidden layer

节点	4	5	6	7	8	9	10	11	12	13	14
均方误差值($\times 10^{16}$)	3.85	9.13	3.26	3.96	3.71	3.89	3.55	3.94	2.91	3.37	4.19

从表 4.3 列出的数据可以看出,当隐含层节点数为 12 时,颤藻生物量预测值与实测值之间的均方误差之值最小,因此,隐含层节点数为 12 时的网络为训练获得的最佳 BP 神经网络。利用这个最佳 BP 神经网络来预测测试数据集中第 10、15、27、30 周对应的颤藻生物量。图 4.3、图 4.4 给出了预测结果。




图 4.5 BP 神经网络对颤藻生物量的预测结果

Fig.4.5 The forecast results of the density of *Oscillatoria* based on the BP neural network




图 4.6 BP 神经网络所得颤藻生物量预测值与实测值的比较

Fig.4.6 Comparison of predicted value and observed value of the density of *Oscillatoria*

由图 4.5、图 4.6 可以看出，BP 神经网络对测试数据集中第 10、15、27、30 周颤藻生物量的预测值与实测值拟合程度较好，两者之间的相关系数达到了 0.984。

4.5.2 敏感度分析结果

图 4.7 给出了颤藻生物量对不同变量施以加、减 10% 干扰的敏感度。由图 6 敏感度分析结果可知，总磷的变化对池塘中颤藻生物量的影响甚微，总氮、透明度、溶解氧和温度的变化对池塘中的颤藻生物量有一定的影响，但影响不大，pH 值的变化对池塘中颤藻生物量的影响较为显著。Yabunaka 等 (1997) 通过分析 Kasumigaura 湖 1981 至 1998 年的数据，得出 pH 值与 chl_a 之间具有很强的正相关关系。他们认为，水体中藻生物细胞数的增加导致光合作用的增加，从而使得水体中碳酸离子增加，引起相应的 pH 值增高。Wei 等 (2001) 在对 Kasumigaura 湖 1982 年至 1996 年的数据进行分析后也发现 pH 值与藻生物量之间具有很强的正相关关系。本研究进行的敏感度分析同样也表明 pH 值与藻生物量之间具有很强的正相关关系，与 Yabunaka 和 Wei 等人的研究结果是一致的，说明 pH 值是宁波大学校内池塘藻类水华的主要驱动因素，为了有效的防治藻类水华的发生，应控制水体的 pH 值。




图 4.7 颤藻生物量对不同变量施以加、减 10% 干扰的敏感度

Fig.4.7 The sensitivity analysis of the density of *Oscillatoria* that carried the interference($\pm 10\%$) on the different variables

4.6 小结

(1) 本文以宁波大学校内池塘颤藻生物量及其影响因子 30 周的监测数据为基础, 应用 BP 神经网络, 以第 (n-1) 周和第 (n-2) 周环境变量的监测数据为网络输入, 以第 n 周颤藻生物量的监测数据为网络输出, 构建 BP 神经网络模型, 对池塘颤藻生物量进行了短期预测。BP 神经网络训练和验证的结果表明, 模型拟合程度良好, 说明 BP 神经网络模型可以用于水体中藻类水华的短期预测。

(2) 通过对构建的 BP 神经网络模型进行敏感度分析, 阐明了宁波大学校内池塘藻类水华的主要驱动因素, 并指出控制水体的 pH 值是宁波大学校内池塘藻类水华防治工作的重点。

5 藻华水体浮游植物群落结构的研究—校内池塘

基于第 4 章中采样池塘的基本情况，对藻华水体浮游植物的群落结构展开研究。

5.1 材料与方法

5.1.1 采样池塘基本情况

见 4.1.1。

5.1.2 样品采集和测定

见 4.2。

5.1.3 数据处理方法

基于英国普利茅斯海洋实验室开发的 PRIMER5.0 群落结构多元统计分析软件，对监测得到的浮游植物群落和环境变量进行多元统计分析，本次分析利用其中的非度量多为尺度转换排序（Non-metric Multi-Dimensional Scaling MDS）、聚类分析（CLUSTER）、ANOSIM 分析、SIMPER 分析、RELATE 检验及 BIO-ENV 分析（Clarke et al,2001; Clarke et al,1993; Clarke et al,1993; Clarke et al,1994; SomerFeld et al,1995）。

5.2 结果与分析

5.2.1 采样池塘环境因子的变化

见 4.2。

5.2.2 采样池塘浮游植物种类组成及其丰度变化

见 4.3。

5.2.3 采样池塘浮游植物群落结构及其与环境因子的关系

5.2.3.1 采样池塘浮游植物群落的演替变化

5.2.3.1.1 浮游植物群落聚类分析及 MDS 分析

浮游植物物种和个体数量组成原始数据矩阵，矩阵的样本为采样次数，共 30 个样本，矩阵的变量为每个样本中的浮游植物物种。将 30 个样本对应的浮游植物物种和细胞个体数量组成的原始矩阵，经过二次方根转换后（Clarke,1993），求出两两样本间的 Bray-Curtis 相似性系数，得到采样池塘浮游植物群落的物种相似性矩阵，在此基础上，经过 CLUSTER 聚类分析和 MDS 排序分析得到采样池塘浮游植物群落的聚类分析树状

图和 MDS 标序图，见图 5.1、图 5.2。




图 5.1 采样池塘浮游植物聚类分析图

Fig.5.1 Dendrogram of phytoplankton community in the sampling pond




图 5.2 采样池塘浮游植物 MDS 标序图

Fig.5.2 MDS ordination of phytoplankton community in the sampling pond

在图 5.1 中以约 40%相似度水平线作为分组界线，将池塘的整个浮游植物群落分为 I 组、II 组和 III 组 3 大组群。由图中可以看出，III 组聚类组内浮游植物组成的相似度最高，I 组次之，II 组最小。

由图 5.2 可知，stress 值为 0.08 (<0.1)，这说明所得到的 MDS 标序图能正确解释样本间的相似关系 (Khalaf et al,2002)。根据图中各样本间的距离远近，可将其分为 I 组、II 组和 III 组 3 大组群，由图中可以看出，III 组内各样本间的距离最小，I 组次之，II 组最大，即 III 组内样本间的相似度大于 I 组和 II 组，II 组最小，且该 MDS 标序图中 3 个组群内的样本和聚类分析图中的样本是完全一样的，其结果与聚类分析也是完全一致的。

5.2.3.1.2 浮游植物群落 ANISIM 分析及 SIMPER 分析

基于图 5.1 和图 5.2 中对池塘浮游植物的聚类分析和 MDS 标序，利用 ANOSIM 分析中的子程序对池塘浮游植物群落的 3 大组群进行 ANOVA 差异显著性检验，以检验池塘浮游植物群落各组群之间的差异性，其检验结果见表 5.1。同时，对池塘浮游植物群落的 3 大组群进行了 SIMPER 分析，选择对各组群累积贡献率大于 90%的藻类物种，以鉴定对各组群起作用的优势藻类种类，其分析结果见表 3。

表 5.1 采样池塘浮游植物群落 3 大组群间的 ANOSIM 分析

Tab 5.1 ANOSIM test of three differences groups of phytoplankton community in the sampling pond

检验对象	R 统计值	显著性水平
I 组和 II 组	0.883	0.004
I 组和 III 组	0.998	0.001
II 组和 III 组	0.924	0.001

由表 5.1 可以看出池塘浮游植物群落各组群之间差异极其显著 ($p < 0.01$)，说明池塘浮游植物群落 3 大组群浮游植物的种类组成之间存在着显著性差异。

表 5.2 采样池塘浮游植物群落 3 大组群间的 SIMPER 分析

Tab 5.2 SIMPER test of three differences groups of phytoplankton community in the sampling pond

组群类别	浮游藻类种类	贡献率 (%)	累积贡献率 (%)
I 组	衣藻	50.18	50.18
	隐藻	29.10	79.28
	四尾栅藻	9.95	89.23
	纤维藻	4.55	93.78
II 组	四尾栅藻	34.39	34.39
	颤藻	27.27	61.66
	席藻	13.71	75.37
	衣藻	12.25	87.61
	隐藻	5.16	92.77
III 组	色球藻	35.61	35.61
	平裂藻	30.54	66.16
	颤藻	12.60	78.76
	螺旋藻	5.83	84.59
	四尾栅藻	4.16	88.74
	项圈藻	3.52	92.26

由表 5.2 可知，I 组的优势藻类种类主要有绿藻和隐藻两大类组成，其中绿藻的贡献率占到了 64.68%，隐藻的仅为 29.10%；II 组的优势藻类种类主要有绿藻、蓝藻和隐藻三大类组成，其中绿藻的贡献率为 46.64%，蓝藻的为 40.98%，隐藻的为 5.16%；III 组的优势藻类种类主要有绿藻和蓝藻两大类组成，其中绿藻的贡献率为 4.16%，蓝藻的达到了 88.11%。由此可见，从第 I 组到第 III 组，绿藻群落的生物量呈现出逐渐减少的趋势，蓝藻群落的生物量从无到有，逐渐增多，并最终占据统治地位，隐藻群落的生物量逐渐减少，并最终消失。从中不难看出，从第 I 组到第 III 组，采样池塘的浮游植物群落呈现出明显的群落演替过程。

结合对池塘的具体采样时间以及对池塘浮游植物群落结构聚类分析和 MDS 标序的结果可知，第 I 组浮游植物组群所对应的采样季节为春季，第 II 组浮游植物组群所对应的采样季节为春末夏初，第 III 组浮游植物组群所对应的采样季节为夏季和秋季，因此，从

第 I 组到第 III 组与对池塘采样时间的先后是一致的。由对采样池塘浮游植物群落 3 大组群间的 SIMPER 分析结果可知, 从第 I 组到第 III 组, 采样池塘的浮游植物群落呈现出明显的群落演替过程。所以, 采样池塘的浮游植物群落也呈现出明显的季节演替过程, 春季主要以绿藻群落为主, 春末夏初绿藻群落逐渐减少, 蓝藻群落逐渐增多, 到了夏季和秋初, 蓝藻群落在池塘的整个浮游植物群落中占据了统治地位。

5.2.3.2 采样池塘浮游植物群落结构和环境因子的 RELATE 相关性检验及 BIO-ENV 匹配性分析

为了进一步研究采样池塘浮游植物群落和环境因子之间的关系, 使用 PRIMER5.0 软件中的 RELATE 检验程序及 BIO-ENV 匹配性分析, 分别对采样池塘整个浮游植物群落和其中的蓝藻群落进行了相关性检验和分析。

5.2.3.2.1 采样池塘整个浮游植物群落和环境因子的 RELATE 相关性检验及 BIO-ENV 匹配性分析

利用 PRIMER5.0 软件对采样池塘整个浮游植物群落进行了 RELATE 相关性检验及 BIO-ENV 匹配性分析。RELATE 检验结果表明: 采样池塘整个浮游植物群落和环境因子的相关系数 $R=0.489$, 显著水平 $P=0.1\%$, 可见, 采样池塘整个浮游植物群落和环境因子的相关性极其显著; BIO-ENV 匹配性分析结果见表 5.3。

表 5.3 采样池塘整个浮游植物群落与环境因子 BIO-ENV 相关分析结果

Tab 5.3 Results of BIO-ENV correlation analysis between the entire phytoplankton community and environmental factors in the sampling pond

环境变量个数 Number of Variables	相关系数 Correlation Coefficient	环境变量子集 Variables Selections
1	0.711	pH
2	0.704	SD,pH
2	0.664	TP,pH
2	0.663	pH,WT
3	0.657	SD,pH,WT
3	0.657	TP,SD,pH
3	0.643	TP,pH,WT
4	0.638	TP,SD,pH,WT
2	0.618	TN,pH
3	0.615	TN,SD,pH

由表 5.3 可以看出, 采样池塘整个浮游植物群落与 pH 之间的相关系数达到了 0.711, 与 SD 和 pH 环境组合之间的相关系数达到了 0.704, 可见, SD 和 pH 这两个环境因子能够很好的解释采样池塘的整个浮游植物群落。pH 为 BIO-ENV 分析结果中所列

出的诸环境因子子集的共有元素，且 pH 与采样池塘整个浮游植物群落之间的相关系数达到了 0.711，这说明 pH 是控制采样池塘整个浮游植物群落的关键因素。此外，TP 也是影响采样池塘整个浮游植物群落结构的重要环境因子。

5.2.3.2.2 采样池塘蓝藻类群和环境因子的 RELATE 相关性检验及 BIO-ENV 匹配性分析

采样池塘是一个小型藻华水体，富营养化程度严重，多年发生蓝藻水华，在对池塘进行样品采集期间，爆发了颤藻水华，并持续数月。为了进一步探究蓝藻群落与环境因子之间的关系，旨在揭示蓝藻群落与环境因子之间的相关性水平，找出影响蓝藻群落最适匹配的环境因子组合及其关键性因子。利用 PRIMER5.0 软件对采样池塘中的蓝藻群落进行了 RELATE 相关性检验及 BIO-ENV 匹配性分析。RELATE 检验结果表明：采样池塘蓝藻群落和环境因子的相关系数 $R=0.449$ ，显著水平 $P=0.1\%$ ，可见，采样池塘蓝藻群落和环境因子的相关性极其显著；BIO-ENV 匹配性分析结果见表 5.4。

表 5.4 采样池塘蓝藻群落与环境因子 BIO-ENV 相关分析结果

Tab 5.4 Results of BIO-ENV correlation analysis between the cyanobacteria phytoplankton community and environmental factors in the sampling pond

环境变量个数 Number of Variables	相关系数 Correlation Coefficient	环境变量子集 Variables Selections
3	0.573	SD, pH, WT
2	0.570	pH, WT
4	0.555	TN, SD, pH, WT
3	0.553	TN, pH, WT
4	0.552	TP, SD, pH, WT
3	0.550	TP, pH, WT
5	0.540	TN, TP, SD, pH, WT
4	0.538	TN, TP, pH, WT
3	0.524	TN, SD, pH
2	0.515	TN, pH

由表 5.4 可以看出，采样池塘蓝藻群落与 SD、PH 和 WT 环境因子组合之间的相关系数为 0.573，与 pH 和 WT 环境因子组合之间的相关系数为 0.570，可见，SD、pH 和 WT 这 3 个环境因子能够很好的解释采样池塘中的蓝藻群落。pH 为 BIO-ENV 分析结果中所列出的诸环境因子子集的共有元素，这说明 pH 是控制采样池塘蓝藻群落的关键因素。此外，TN 也是影响采样池塘蓝藻群落结构的重要环境因子。

5.3 小结与讨论

在对采样池塘进行为期 30 周的跟踪监测过程中, 采样池塘浮游植物丰度繁盛期过程可分为绿藻期、绿藻和蓝藻期、蓝藻期三个阶段, 其中绿藻在春季大量繁盛形成高峰期, 绿藻和蓝藻在春末夏初大量繁盛共同形成高峰期, 蓝藻在夏季大量繁盛形成高峰期, 并延续至秋季。

结合对池塘的具体采样时间以及对池塘浮游植物群落结构聚类分析和 MDS 标序的结果可知, 采样池塘的浮游植物群落也呈现出明显的季节演替过程, 春季主要以绿藻群落为主, 春末夏初绿藻群落逐渐减少, 蓝藻群落逐渐增多, 到了夏季和秋初, 蓝藻群落在池塘的整个浮游植物群落中占据了统治地位。雷安平等(2003)通过对武汉东湖浮游藻类物种多样性的研究, 指出植物群落演替是一个复杂的过程, 植物群落演替最明显的特征是优势种的演替。谭啸等(2009)通过研究升温过程对藻类复苏和群落演替的影响, 得出藻类群落组成随着温度的升高而逐步发生变化, 绿藻在 12.5℃和 16℃时占优势, 而蓝藻在 19.5℃以后逐步取得优势, 且蓝藻在复苏后的生长速率高于绿藻, 并最终导致蓝藻水华的发生。

本文中通过对采样池塘中的浮游植物群落聚类分析和 MDS 标序分析, 得出采样池塘的优势藻类是蓝藻和绿藻, 且其繁盛过程分为绿藻期、绿藻和蓝藻期和蓝藻期三个阶段, 并存在着这两个优势藻类群落演替的过程。再通过采样池塘温度随时间的监测值可知, 采样池塘中绿藻和蓝藻的演替过程与温度的变化相对应的, 即温度低的阶段绿藻占优势, 随着温度的升高, 蓝藻开始复苏, 并大量繁殖, 出现绿藻和蓝藻并存的局面, 蓝藻的生长速率高于绿藻, 蓝藻的大量繁殖抑制了绿藻的生长, 并最终取得优势。因此, 本文对采样池塘浮游植物群落演替过程的研究与雷安平和谭啸等人的研究结果是一致的, 说明本文采样池塘浮游植物群落呈现出的季节演替过程遵循着季节演替的规律。

通过对采样池塘整个浮游植物群落和蓝藻群落与环境因子之间进行 RELATE 相关性检验及 BIO-ENV 匹配性分析结果可知, 两个群落与池塘环境因子之间的相关性都是极其显著的, 并且 pH 既是采样池塘整个浮游植物群落的关键控制因素, 也是采样池塘蓝藻群落的关键控制因素, 由此可见, pH 对采样池塘浮游植物的群落结构是极其重要的。另外, TP 是影响采样池塘整个浮游植物群落结构的重要环境因子, 而 TN 是影响采样池塘蓝藻群落结构的重要环境因子。Wei 等(2001)通过对日本 Kasumigaura 湖 1982-1996 年的监测数据进行分析, 研究结果表明水体的 pH 值与浮游植物生物量之间具有很强的正相关关系, 并指出水体中浮游植物生物细胞数的增加导致光合作用的增加, 从而使得水体中碳酸离子增加, 引起水体相应的 pH 值增高。López-Archilla 等(2004)通过对西班牙西南部一个富营养化的浅水型湖泊 Santa Olalla 湖中以蓝藻占统治地位的浮游

植物生物量和水体 pH 值之间相互关系的研究,得出水体 pH 值的升高引起了浮游植物的大量繁殖,并导致蓝藻水华的发生。由此可见,pH 影响着水体浮游植物的生物量,进而影响着水体的浮游植物群落结构,本文的研究结果与 Wei 和 López-Archilla 等人的研究结果是一致的。TN、TP 作为水体浮游植物生长的营养盐,其含量的变化影响着水体浮游植物的生物量,进而影响水体浮游植物的群落结构,因此,TN、TP 是影响采样池塘浮游植物群落的重要环境因子,而 pH 是影响采样池塘浮游植物群落的关键控制因子。

浮游植物群落是水环境中的初级生产者和食物链的基础环节,在水生态系统的物质循环、能量流动和信息传递中起着至关重要的作用(李敦海等,2007;张婷等,2006;孙军等,2004),在水生态系统的研究中具有重要的意义。本文通过对藻华池塘浮游植物群落结构的研究,指出其浮游植物群落结构有明显的季节演替过程,群落结构不太稳定,存在暴发藻华的可能性,对藻华池塘进行监测期间,颤藻水华的暴发证明了这一点,因此,定期开展对藻华水体浮游植物群落结构的监测和分析对藻华的预警和防治有着十分重要的现实意义。

6 总结与展望

6.1 本研究的创新之处

1.在构建亭下水库和梅湖水库叶绿素 a 浓度预测模型的过程中，引入了先进的多元统计分析方法（主成分分析）对影响水体叶绿素 a 浓度的环境因子进行了分析，选出了影响水体叶绿素 a 浓度的主要环境变量作为模型构建时的输入变量，通过主成分分析选出的这些输入变量能够有效的减小 BP 网络的“噪音”，加快网络的训练速度，减小网络的训练误差，结果表明主成分分析能够显著的提高网络的性能，具有一定的创新性。

2.预测模型构建后，为了进一步分析网络输入的各个环境变量对网络输出的影响大小，从而确定哪些环境变量对网络输出起主要作用，本文对构建后的预测模型进行了敏感度分析，通过敏感度分析在主成分分析的基础上进一步提取环境变量，最终选出了影响网络输出的主要驱动因子，敏感度分析结果表明，选出的主要驱动因子对网络输出的变化起到一定的指导作用，并具有良好的实际应用价值。

3. 基于 PRIMER5.0 群落结构多元统计分析软件，利用其中的非度量多维尺度转换排序（Non-metric Multi-Dimensional Scaling MDS）和聚类分析（CLUSTER）等多元统计分析方法，对藻华池塘浮游植物群落结构进行了研究，在预测模型的基础上，进一步探求了采样池塘浮游植物群落结构的动态变化及其与环境因子的关系。

6.2 研究展望

BP 人工神经网络作为人工神经网络中最常用的结构之一，已被广泛的运用于水生态系统预测模型的构建中，目前，基于 BP 人工神经网络，国内外已开展了许多有关水体叶绿素 a 浓度和藻类水华预测模型方面的研究，并取得了较大的进展。

本文利用 BP 人工神经网络方法构建了亭下水库和梅湖水库叶绿素 a 浓度的预测模型以及宁波大学校内小型藻华水体的藻华预测模型，对藻类水华的预报预警进行了有益的探索，但是，在模型构建过程中用到的监测数据仅仅是对两个饮用水水库周年跟踪监测的数据以及对小型藻华水体 30 周连续跟踪监测的数据，网络模型输入数据量的不足，导致无法实现对水体叶绿素 a 浓度或藻类水华的长期预测，使得预报预警工作存在一定的局限性；此外，在构建预测模型时并没有把浮游动物以及其他的一些水体环境变量作为网络模

型的输入变量考虑在内，并且对网络模型的输入变量以及隐含层节点的选择问题还没有统一的方法，只能靠一些经验方法来实现，势必会影响到网络预测模型的准确性与可行性。这些都将为进一步开展研究的方向。

参考文献

- [1] Altrock C. Fuzzy logic and neuro fuzzy applications explained[J]. New Jersey: Prentice Hall,1995.
- [2] Amari S I, Murata N K R, Finke M, *et al.* Asymptotic statistical theory of overtraining and cross-validation[J]. IEEE trans.on Neural Networks, 1997, 8(5): 985-996.
- [3] Bierman V J. Mathematical model of the selective enhancement of blue-green algae by nutrient enrichment. In Recknagel F., ANNA-artificial neural network model for predicting species abundance and succession of blue-green algae[J]. Hydrobiologia, 1976, 349(1997): 47-57.
- [4] Brzezinski M A. Cell-cycle effects on the kinetics of silicic acid uptake and resource competition diatoms [J]. Journal of Plankton Research, 1992, 14: 1511-1536.
- [5] Carmichael W W. The toxin of cyanobacteria.1994, Sci.Am., 270.
- [6] Celik A E, Karatepe Y. Evaluating and forecasting banking crises through neural network models:An application for Turkish banking sector[J]. Expert Systems with Applications, 2007, 33(4): 809-815.
- [7] Chen Q W, Mynett A E. Integration of data mining techniques and heuristic knowledge in fuzzy logic modeling of algal biomass in the north sea. Second international workshop on coastal eutrophication (proceedings), Nov.2002. Chongqing: China.
- [8] Clark K R, Warwick R M. Changes in marine communities: an approach to statistical analysis and interpretation[M]. Plymouth: Primer-ELtd, 2001.
- [9] Clarke K R, Ainsworth M. A method of linking multivariate community structure to environmental variables [J]. Marine Ecology Progress Series, 1993, 92: 205-219.
- [10] Clarke K R, Warwick R M. Change in marine communities: an approach to statistic analysis and interpretation[M]. Plymouth Marine Laboratory, UK, 1994,144 pp.
- [11] Clarke K R. Nonparametric multivariate analyses of changes in community structure[J]. Ecology, 1993, 18:117-143.
- [12] Clarke R. Non-parametric multivariate analyses of changes in community structure[J]. Australian Journal of Ecology, 1993, 18: 117-143.
- [13] Codd G A. Cyanobacterial toxins, the perception of water quality, and the prioritisation of eutrophication control[J]. Ecological Engineering, 2000, 16: 51-60.
- [14] Czogala J. Fuzzy and neuro-fuzzy intelligent systems. NewYork: PHysica-Verlag, 2000.
- [15] Daubenmire R F. 1977, Plant and Environment, SecondWiley.
- [16] Dillon P J, Rigler F H. The pHosphorus-chlorophyll relationship in lakes[J]. Limnol.Oceanogr, 1975, 19: 767-773.
- [17] Dimopoulos Y, Chronopoulos J, Chronopoulou S A, *et al.* Neural network models to study relationships between lead concentration in grasses and permanent urban descriptors in Athens city[J]. Ecological Modelling, 1999, 120: 157-165.
- [18] Engin M, Demira S, Engin E Z, *et al.* The classification of human tremor signals using artificial neural network[J]. Expert Systems with Applications, 2007, 33(3): 754-761.
- [19] Eugen P. Odum, 1983, Basic Ecology, CBS, College Pub.
- [20] French M, Recknagel F. Modelling of algal blooms in freshwaters using artificial neural

- networks. In: Zanetti P. (Editor), *Computer Techniques in Environmental Studies V. Vol. II: Environmental Systems*. Southampton, Boston: Computational Mechanics Publications, 1994: 87-94.
- [21] Goh A T C. Back-propagation neural networks for modeling complex systems[J]. *Artif. Intel. Eng.* 1995, 9: 143-151.
- [22] Grznar J, Prasad S, Tata J. Neural networks and organizational systems: Modeling non-linear relationships[J]. *European Journal of Operational Research*, 2007, 181(2): 939-955.
- [23] Holm N P, Armstrong D E. Role of nutrient limitation and competition in controlling the populations of *Asterionella Formosa* and *Microcystis aeruginosa* in semicontinuous culture[J]. *Limnology and Oceanograph*, 1981, 26 (4) :622-634.
- [24] Hou G X, Song L R, Liu J T, et al. Modelling of cyanobacterial blooms in hypereutrophic Lake Dianchi, China [J]. *Journal of Fresh water Ecology*, 2004, 19(4): 623-629.
- [25] Ingrid C, Jamie B. *Toxic Cyanobacteria in water* [M]. London and New York. E&FN Spon publisher, 1999, 416.
- [26] Jeong K S, Joo G J, Kim H W, et al. Prediction and elucidation of phytoplankton dynamics in the Nakdong River (Korea) by means of a recurrent neural network[J]. *Ecological Modelling*, 2001, 146: 115-129.
- [27] Jeong K S, Joo G J, Kim H W, et al. Recknagel F. Prediction and elucidation of phytoplankton dynamics in the Nakdong River (Korea) by means of a recurrent neural network[J]. *Ecological Modelling*, 2001, 146: 115-129.
- [28] Jeong K S, Recknagel F, Joo G J. Prediction and elucidation of population dynamics of the blue-green algae *Microcystis aeruginosa* and the diatom *Stephanodiscus hantzschii* in the Nakdong River Reservoir systems (South Korea) by a recurrent artificial neural network. In: Recknagel F., *Ecological Informatics* (2nd Edition). NY: Springer-Verlag, 2005: 255-273.
- [29] Joseph H W Lee, Yan Huang, Mike Dickman, et al. Neural network modelling of coastal algal blooms[J]. *Ecological Modelling*, 2003, 159: 179-201.
- [30] Khalaf A, Kochzius M. Changes on trophic community structure of shore fishes at an industrial site in the gulf of Aqaba, red sea[J]. *Marine Ecology Progress Series*, 2002, 239: 287-299.
- [31] Klausmeier C A, Litchman E, Daufresne T, et al. Optimal nitrogen to phosphorus stoichiometry of phytoplankton[J]. *Nature*, 2004, 429: 171-174.
- [32] Kunwar P S, Ankita B, Amrita M, et al. Artificial neural network modeling of the river water quality-A case study[J]. *Ecological Modelling*, 2009, 220: 888-895.
- [33] Lek S, Delacoste M, Baran P, et al. Application of neural networks to modeling non-linear

- relationships in ecology[J]. Ecological Modelling, 1996, 90: 39-52.
- [34] Liu Y, Han M, Liang Z, et al. Influence of light intensity, temperature and nutrients on the growth of *Microcystis* in water of Dianchi Lake[J]. Res. Environ. Sci., 1995, 8: 7-11.
- [35] López-Archilla A I, Moreira D, López-García P, et al. Phytoplankton diversity and cyanobacterial dominance in a hypereutrophic shallow lake with biologically produced alkaline pH [J]. Extremophiles, 2004, 8:109-115.
- [36] Ma X X, He X J, Zhao D Q, et al. Influence of BP networks hidden layer on water quality evaluation result[J]. International Journal Hydroelectric Energy, 2002, 20: 16-18.
- [37] Maier H R, Dandy G C, Burch M D. Use of artificial neural networks for modeling cyanobacterial *Anabaena* spp. in the River Murray, South Australia[J]. Ecological Modelling, 1998, 105: 257-272.
- [38] Maier H R, Dandy G C. Modelling cyanobacterial (blue-green algae) in the River Murray using artificial neural networks[J]. Mathematics and computers in Simulation, 1997, 43: 377-386.
- [39] Marsili L S. Fuzzy prediction of the algal blooms in the Orbetello Lagoon[J]. Environmental Modeling and Software, 2004, 19(9): 799-808.
- [40] Michael F P, Julianne D, Pia H M, et al. Effects of modified nutrient concentrations and ratios on the structure and function of the native phytoplankton community in the Neuse River Estuary, North Carolina, USA [J]. Aquat Ecol, 2002, 36: 371~385.
- [41] Nydick K R, Lafrancois B M, Baron J S, et al. Nitrogen regulation of algal biomass, productivity, and composition in shallow mountain lakes, Snowy Range, Wyoming, USA[J]. Can J Fish Aquat Sci, 2004, 61: 1256~1268.
- [42] Peter L M., Goethals A P, Dedeker W G, et al. Applications of artificial neural networks predicting macroinvertebrates in freshwaters[J]. Aquatic Ecology, 2007, 41: 491-508.
- [43] Pick F R. Species-specific phytoplankton responses to nutrient enrichment in limnetic enclosures[J]. Arch Hydrobiol Beih Ergeb Limnol, 1989, 32: 177~187.
- [44] Ráduly B, Gernaey K V, Capodaglio A G, et al. Artificial neural networks for rapid WWTP performance evaluation: Methodology and case study[J]. Environmental Modelling & Software, 2007, 22(8): 1208-1216.
- [45] Recknagel F, French M, Harkonen P, et al. Artificial neural network approach for modelling prediction of algal blooms[J]. Ecol. Modelling, 1997, 96: 11-28.
- [46] Recknagel F, Petzoldt T, Jaeke O, et al. Hybrid expert system DELAQUA-a toolkit for water quality control of lakes and reservoirs[J]. Ecol. Modelling, 1994, 71: 17-36.
- [47] Redfield A C. The biological control of chemical factors in the environment[J]. Am Sci, 1958, 46: 205-222.
- [48] Reynolds F M. The ecology of freshwater phytoplankton[J]. Cambridge: Cambridge

University Press, 1984: 384.

- [49] Rivals I, Personnaz L. On cross validation for model selection[J]. Neural computation, 1999, 11: 863-870.
- [50] Rong Z, Hong Y, Ping D L. Research on Prediction of Red Tide Based on Fuzzy Neural Network[J]. Marine Science Bulletin, 2006, 8(1): 83-92.
- [51] Sakamoto M. Primary production by pHytoplankton community in some Japanese lakes and its dependence on lake depth[J]. Arch.Hydrobiol., 1966, 62:1-28.
- [52] Saowapa A, SupHapHorn R. Seasonal variation of pHytoplankton community in Thale Sap Songkhla-a lagoonal lake in southern thailand[J]. Netherlands journal of aquatic ecology, 1997, 30(4): 297-307.
- [53] Siginer I. Some artificial neural network applications to greenhouse environmental control [J]. Comput. Electron. Agric., 1997, 18: 167-186.
- [54] Somerfeld P J, Rees H L, Warwick R M. Interrelationship in community structure between shallow-water marine meiofauna and macrofauna in relation to dredgings disposal[J]. Marine Ecology Progress Series, 1995, 127:103-112.
- [55] Soyupak S, Chen D G. Fuzzy logic model to estimate seasonal pseudo steady state chlorophyll-a concentration in reservoirs[J]. Environmental Modeling Assessment, 2004, 9(1): 51-59.
- [56] Sugiura N, Utsumi M, Wei B, et al. Assessment for the complicated occurrence of nuisance odours from pHytoplankton and environmental factors in a eutrophic lake[J]. Lakes&Reservoirs:Research and Management, 2004, 9: 195-201.
- [57] Tilman D, Kiesling, R L. Freshwater algal ecology: taxonomic tradeoffs in the temperature dependence of nutrient competitive abilities.—In: M. J. Klug & C. A. Reddy, eds, Current Perspective in Microbial Ecology, Proceedings of the 3rd International Symposium on Microbial Ecology, 1984.
- [58] Tilman D, Kilham S S, Kilham P. Phytoplankton community ecology: The role of limiting nutrients[J]. Annu Rev Ecol Syst, 1982, 13: 349~372.
- [59] Tzafestas S G, Dalianis P J, Anthopoulos G. On the overtraining phenomenon of backpropagation neural networks[J]. Mathematics and Computers in Simulation, 1996, 40: 507-521.
- [60] Velo-Suárez L, Gutiérrez-Estrada J C. Artificial neural network approaches to one-step weekly prediction of Dinophysis acuminata blooms in Huelva(Western Andalucía, Spain) [J]. Harmful Algae, 2007, 6: 361-371.
- [61] Walter M, Recknagel F, Carpenter C, et al. Predicting eutrophication effects in the Burrenjack Reservoir(Australia)by means of the deterministic model SALMO and the

- recurrent neural network model ANNA[J]. Ecological Modelling, 2001, 146: 97-113.
- [62] Wei B, Sugiura N, Maekawa T. Use of artificial neural network in the prediction of algal blooms[J]. Water Resource, 2001, 35(8): 2022-2028.
- [63] Whitehead P G, Howard A, Arulmani C. Modelling algal growth and transport in rivers:a comparison of time series analysis,dynamic mass balance and neural network techniques[J]. Hydrobiologia, 1997, 349: 39-46.
- [64] Whitehead P, Hornberger G. Modelling algal behaviour in the River Thames[J]. Wat.Res.,1984, 18: 945-953.
- [65] Xiong L H, Guo S L, Wang Y. Study and application of artificial neural network in real time flood forecasting[J]. International Journal Hydroelectric Energy, 2002, 20: 28-31.
- [66] Yabunaka K I, Hosomi M, Murakami A. Novel application of a back-propagation artificial neural network model formulated to predict algal bloom[J]. Wat.Sci.Tech., 1997, 36(5): 89-97.
- [67] Zar J H. Biostatistical Analysis, 2nd edition. NJ: Prentice-Hall, 1984: 718.
- [68] Zhao et al. Water quality forecast through application of BP neural network at Yuqiao reservoir[J]. Zhejiang Univ SciA 2007 8(9): 1482-1487.
- [69] Zou H, Xia G, Yang F, et al. A neural network model based on the multi-stage optimization approach for short-term food price forecasting in China[J]. Expert Systems with Applications, 2007, 33(2): 347-356.
- [70] 常晓丽. 基于 Matlab 的 BP 神经网络设计[J]. 机械工程与自动化, 2006, 137(4): 36-37.
- [71] 陈立婧, 彭自然, 孔优佳, 等. 江苏太湖浮游藻类群落结构特征[J]. 生态学杂志, 2008, 27(9): 1549-1556.
- [72] 方云英, 杨肖娥, 濮培民, 等. 宁波力洋水库富营养化现状及生态治理对策[J]. 水土保持学报, 2004, 18(6): 183-186.
- [73] 韩茂森, 束蕴芳编绘. 中国淡水生物图谱[M]. 北京: 海洋出版社, 1995.
- [74] 何亮. 主成分分析在 SPSS 中的应用[J]. 山西农业大学学报, 2007, 6(5): 20-22.
- [76] 胡鸿钧, 魏印心. 中国淡水藻类——系统、分类及生态[M]. 北京: 科学出版社, 2006.
- [75] 黄良民, 钱宏林, 李锦蓉. 大鹏湾赤潮多发区的叶绿素 a 分布与环境关系初探 [J]. 海洋与湖沼, 1994, 25(2): 197-205.
- [76] 金春华, 陆开宏, 王扬才, 等. 浙江省 3 座饮用水水库的蓝藻控制对策及效果 [J]. 水利渔业, 2005, 25(3): 50-55.
- [77] 金相灿, 屠清瑛. 湖泊富营养化调查规范 (第二版) [M]. 北京: 中国环境科学出

版社, 1990.

- [78] 雷安平, 施之新, 魏印心. 武汉东湖浮游藻类物种多样性的研究[J]. 水生生物学报, 2003, 27(2): 179-184.
- [79] 李敦海, 李根宝. 水华蓝藻生物质对沉水植物五刺金鱼藻生长的影响[J]. 水生生物学报, 2007, 31(5): 689-692.
- [80] 林佳, 苏玉萍, 余榕霞, 等. 应用人工神经网络模型研究福建省山仔水库叶绿素 a 动态[J]. 亚热带资源与环境学报, 2007, 2(4): 33-40.
- [81] 林金美, 张水浸, 王初升. 一起与赤潮有关的贝类中毒事件的调查[J]. 海洋环境科学, 1988, 7(1): 22-25.
- [82] 刘东艳, 孙军. 胶州湾浮游植物研究[J]. 青岛海洋大学学报, 2002, 32(3): 415-421.
- [83] 刘家寿, 陈文祥, 黄永川, 等. 浮桥河水库的营养状况与水质调控措施[J]. 长江流域资源与环境, 2001, 10(4): 360-364.
- [84] 刘建萍, 张玉超. 太湖叶绿素 a 浓度预测模型初探[J]. 环境保护科学, 2009, 35(4): 46-49.
- [85] 刘世枚, 黎尚豪. 两种蓝藻种群间的相互作用[J]. 植物学报, 1991, 33(2): 110-117.
- [86] 刘娅琴, 邹国燕. 框式复合型生态浮床对富营养水体浮游植物群落结构的影响[J]. 水生生物学报, 2010, 34(1): 196-203.
- [87] 刘元波, 陈伟民. 湖泊藻类动态模拟[J]. 湖泊科学, 2000, 12(2): 171-176.
- [88] 卢大远, 刘培刚, 范天俞, 等. 汉江下游突发水华的调查研究[J]. 环境科学研究, 2000, 13(2): 28-31.
- [89] 罗成汉. 基于 MATLAB 神经网络工具箱的 BP 网络实现[J]. 计算机仿真, 2004, 21(5): 109-111.
- [90] 梅卓华, 张哲海, 赵春霞, 等. 南京玄武湖蓝藻水华治理后水质和浮游植物的动态变化[J]. 湖泊科学, 2010, 22(1): 44-48.
- [91] 潘继征, 熊飞. 抚仙湖浮游植物群落结构、分布及其影响因子[J]. 生态学报, 2009, 29(10): 5376-5385.
- [92] 裴洪平, 罗妮娜, 蒋勇. 利用 BP 神经网络方法预测西湖叶绿素 a 的浓度[J]. 生态学报, 2004, 24(2): 246-251.
- [93] 裴洪平, 马建义, 周宏, 等. 杭州西湖藻类动态模型研究[J]. 水生生物学报,

- 2000, 24(2): 143-149.
- [94] 齐雨藻, 洪英, 吕颂辉, 等. 南海大鹏湾海洋褐胞藻赤潮及其成因[J]. 海洋与湖沼, 1994, 25(2): 132-138.
- [95] 邱靖, 杨毅, 张亚静, 等. 基于改进 BP 网络模型的水质预测模型的研究[J]. 云南农业大学学报, 2007, 22(3): 417-422.
- [96] 曲克明, 陈碧鹃, 袁有宪, 等. 氮磷营养盐影响海水浮游硅藻种群组成的初步研究[J]. 应用生态学报, 2000, 11(3): 445-448.
- [97] 沈韞芬, 章宗涉. 微型生物监测新技术[M]. 北京: 中国建筑工业出版社, 1990.
- [98] 苏玉萍, 陈娜蓉, 林婉珍, 等. 福建省山仔水库浮游植物特征与水体富营养状况分析[J]. 亚热带资源与环境学报, 2006, 1(2): 48-54.
- [99] 孙军, 刘东艳. 多样性指数在海洋浮游植物研究中的应用[J]. 海洋学报, 2004, 26(1): 62-75.
- [100] 孙凌, 金相灿, 钟远等不同氮磷比条件下浮游藻类群落变化[J]. 应用生态学报, 2006, 17(7): 1218-1223.
- [101] 孙蓉桦, 张微. GRNN 和遗传算法在赤潮预报中的应用操作[J]. 科技通报, 2005, 21(4): 485-490.
- [102] 谭啸, 孔繁翔, 等. 升温过程对藻类复苏和群落演替的影响[J]. 中国环境科学, 2009, 29(6): 578-582.
- [103] 王得玉, 冯学智, 周立国, 等. 太湖蓝藻爆发与水温的关系的 MODIS 遥感[J]. 湖泊科学, 2008, 20(2): 173-178.
- [104] 邬红娟, 郭生练, 胡传林, 等. 水库浮游植物群落动态的人工神经网络方法[J]. 海洋与湖沼, 2001, 32(3): 267-273.
- [105] 吴生才, 陈伟民. 太湖浮游植物生物量的周期性变化[J]. 中国环境科学, 2004, 24(2): 151-154.
- [106] 吴玉霖, 孙松, 张永山, 等. 胶州湾浮游植物数量长期动态变化的研究[J]. 海洋与湖沼, 2004, 35(6): 518-523.
- [107] 奚万艳, 吴鑫, 叶文瑾, 等. 太湖梅梁湾水域蓝藻水华前与水华末期细菌群落结构的变化[J]. 应用与环境生物学报, 2007, 13(1): 97-103.
- [108] 谢中华. 运用混合回归模型预报赤潮[J]. 海洋技术, 2004, 23(1): 27-30.
- [109] 许金花, 潘伟斌, 张海燕. 城市小型浅水人工湖泊浮游藻类与水质特征研究[J]. 生态科学, 2007, 26(1): 36-40.
- [110] 阎平凡. 人工神经网络与模拟进化计算[M]. 北京: 清华大学出版社, 2000

- [111] 杨建刚, 人工神经网络实用教程. 杭州: 浙江大学出版社. 2001
- [112] 虞功亮, 宋立荣, 李仁辉. 中国淡水微囊藻属常见种类的分类学讨论—以滇池为例[J]. 植物分类学报, 2007, 45 (5): 727-741.
- [113] 张婷, 宋立荣. 铜绿微囊藻 (*Microcystis aeruginosa*) 与三种丝状藻间的相互作用[J]. 湖泊科学, 2006, 18(2): 150-156.
- [114] 张维昊, 徐小青, 丘昌强. 水环境中微囊藻毒素研究进展[J]. 环境科学研究, 2001, 14(2): 57-61.
- [115] 张尧庭, 方开泰. 多元统计分析引论[M]. 北京: 科学出版社, 1997.
- [116] 张哲海. 玄武湖蓝藻水华应急治理成效分析[J]. 污染防治技术, 2006, 19(5): 56-59.
- [117] 张志兵, 施心路, 刘桂杰, 等. 杭州西湖浮游藻类变化规律与水质的关系[J]. 生态学报, 2009, 29(6): 2980-2988.
- [118] 章宗涉, 黄祥飞. 淡水浮游生物研究方法[M]. 北京: 科学出版社, 1991.
- [119] 赵孟绪, 雷腊梅, 韩博平. 亚热带水库浮游植物群落季节变化及其影响因素分析—以汤溪水库为例[J]. 热带亚热带植物学报, 2005, 13(5) : 386-392.
- [120] 赵明桥, 李攻科, 张展霞. 应用多元回归法研究赤潮特征有机物与赤潮关系[J]. 中山大学学报(自然科学版), 2003, 42(1): 35-39.
- [121] 赵影, 王志强, 杨志平, 等. 巢湖取水口浮游藻类污染调查[J]. 环境与健康杂志, 2002, 19(4): 316-318.
- [122] 周广杰, 况琪军, 胡征宇. 三峡库区四条支流藻类多样性评价及水华防治[J]. 中国环境科学, 2006, 26(3): 337-341.
- [123] 周继成. 人工神经网络[M]. 北京: 科学普及出版社, 1993.
- [124] 朱从举, 齐雨藻, 郭昌弼. 铁、氮、磷、维生素B₁和B₁₂对海洋原甲藻的生长效应[J]. 海洋与湖沼, 1994, 25(2): 168-172.

在 学 研 究 成 果

一、 在学期间取得的科研成果

无

二、 在学期间所获的奖励

无

三、 在学期间发表的论文

张克鑫, 陆开宏, 金春华, 朱津永, 刘夏松, 谢丽凤. 基于 BP 神经网络的湖南镇水库叶绿素 a 浓度预测模型的研究[J]. 海洋湖沼通报. 录用待刊.

谢丽凤, 陆开宏, 胡智勇, **张克鑫**, 刘夏松. 多花黑麦草对不同形态氮的吸收动力学特征研究[J]. 生态科学, 2010, 29(3): 229-233.

刘夏松, **张克鑫**, 吕敬, 陆开宏. 铜锈环棱螺对藻华水体理化指标的影响[J]. 生态科学, 录用待刊.

致 谢

在论文完成之际，我的心情久久不能平静。在宁波大学学习的这短短的两年半时间中有很多事情历历在目。经过快三年的磕磕碰碰，虽然还有所遗憾，但我能问心无愧的说自己没有荒废这段光阴。能够顺利完成试验和论文不仅是自己努力的结果，更是众人的智慧和力量的结晶。因此，谨以此文表达自己由衷的谢意！

首先要感谢我的导师陆开宏教授，是您给我进一步深造的机会，是您为我提供了优良的学习平台和良好的工作条件，对我的生活也是无微不至的关怀。本论文从选题、实验设计、结果分析到最后定稿，无不倾注了导师的心血与智慧。您渊博的知识、严谨的治学态度、忘我的工作热忱、活跃的思维方式和对科学的执着态度使我受益匪浅！至此论文完成之际，向老师您致以最崇高的敬意和最真挚的祝福！

这里我还要感谢郑忠明副教授、金春华副教授、徐镇老师、徐永健老师在我完成论文过程中给予的建议和支持；感谢宁波市环境监测中心在课题合作中数据检测方面的帮助；感谢朱津永、胡智勇、孙思志、张春景和梁晶晶等师兄、师姐在学习生活中对我的无私帮助；感谢刘夏松、曹霄、谢丽凤、傅彩萍、吕敬等同学在学习生活中对我的关心和帮助；感谢邵路路、钱伟、翟海佳、孙芳等师弟、师妹等在实验过程以及学习生活中对我的关心和帮助，我的论文中同样凝结着你们的艰辛劳动，能够与你们共度这段时光是我一生的幸运。

本研究得到国家自然科学基金（30771658）、宁波市重大（重点）科技攻关计划项目（2008C50017）联合资助，在此一并表示诚挚的感谢！

最后我要感谢我的父母给予我的无私无尽的支持，衷心感谢你们多年来在我成长的道路上付出的心血和汗水。是您们默默的支持和鼓励让我有了不竭的动力，是您们的开导和理解给我不懈的勇气。最后让我再一次对所有帮助、关心过我老师和同学表示最衷心的感谢，谢谢你们！

张克鑫

2010年10月于宁波